

國立虎尾科技大學

資訊管理系碩士班

碩士論文

基於物料清單的知識圖譜建構與多來源資料整合方法

**Knowledge Graph Construction Based on Bill of
Materials and Multi-Source Data Integration Method**

研究生：張婷穎

指導教授：楊達立

中華民國 115 年 7 月

基於物料清單的知識圖譜建構與多來源資料整合方法
Knowledge Graph Construction Based on Bill of
Materials and Multi-Source Data Integration Method

研究生：張婷穎
指導教授：楊達立

Student：Ting-Ying Chang
Advisor：Dar-Li Yang

國立虎尾科技大學
資訊管理系碩士班
碩士論文

A Thesis Submitted to Department of Information Management
College of Management
National Formosa University
in Partial Fulfillment of the Requirements
for the Degree of Master
in
Information Management

July, 2026
Huwei, Yunlin, Taiwan (R.O.C.)

中華民國 115年7月

國立虎尾科技大學論文口試委員審定書

資訊管理系碩士班

張梓穎 君

中文論文題目：基於物料清單的知識圖譜建構與多來源資料整合方法

英文論文題目：Knowledge Graph Construction Based on Bill of Materials
and Multi-Source Data Integration Method

合於碩士資格水準，業經本委員會評審認可。

論文考試委員簽名：

許洲榮

郭文宏

楊達立

指導教授簽名：

楊達立

系主任簽名：藍友烽

中華民國 115 年 7 月 13 日

基於物料清單的知識圖譜建構與多來源資料整合方法

學生：張婷穎

指導教授：楊達立

國立虎尾科技大學資訊管理系碩士班

摘要

本研究探討大型語言模型（Large Language Model, LLM）於知識圖譜（Knowledge Graph, KG）建構過程中所面臨的語意不一致與結構錯誤問題，特別是在多來源資料整合情境下，容易產生實體名稱重複、關係語意不一致及層級結構混亂等現象，進而影響知識圖譜的品質與可用性。為解決上述問題，本研究提出一套結合物料清單（Bill of Materials, BOM）結構約束與多來源 LLM 輸出整合的知識圖譜建構方法。

本方法首先透過多個 LLM 將自然語言轉換為包含實體、關係及 BOM 層級資訊的 JavaScript Object Notation (JSON) 結構，並透過資料重組與語意分類機制進行關聯統整、冗餘資訊去除與結構補全。在多來源整合階段，進一步透過實體對齊、關係一致化與結構驗證機制整合不同模型的輸出結果，以提升跨來源資料的一致性與完整性。實驗設計方面，本研究以案例分析方式，比較單一 LLM 與多來源整合方法在實體正確性、關係語意一致性及 BOM 層級結構完整性的表現，並據以評估不同方法的差異。

實驗結果顯示，相較於單一 LLM 方法，本研究所提出的多來源整合與 BOM 結構約束機制，明顯降低實體命名不一致與關係錯誤的發生率，並有效改善層級結構的混亂問題，同時整體提升知識圖譜的品質。綜合而言，本研究建立一套具可重現性與實務應用價值的知識圖譜建構流程，適用於多來源資料整合情境，並可應用於具層級結構與複雜關聯的知識建構與管理任務。

關鍵詞：知識圖譜、大型語言模型、物料清單、多來源資料整合、結構一致性。

Knowledge Graph Construction Based on Bill of Materials and Multi-Source Data Integration Method

Student : Ting-Ying Chang

Advisor : Dar-Li Yang

Department of Information Management
National Formosa University

Abstract

This study investigates the semantic inconsistencies and structural errors that occur when Large Language Models (LLM) are applied to Knowledge Graph (KG) construction, particularly in multi-source data integration scenarios. Common challenges include duplicate entity names, inconsistent relationship semantics, and disordered hierarchical structures, all of which undermine the quality and usability of the resulting knowledge graph. To address these issues, this study proposes a KG construction method that incorporates Bill of Materials (BOM) structural constraints with consolidated outputs from multiple LLMs.

The proposed approach first employs multiple LLMs to transform natural language into a JavaScript Object Notation (JSON) structure that encapsulates entities, relationships, and BOM-level information. Data reorganization and semantic classification mechanisms are then applied to consolidate associations, eliminate redundancies, and complete missing structures. During the multi-source integration stage, entity alignment, relationship harmonization, and structural validation mechanisms are further introduced to merge outputs from different models, thereby enhancing cross-source consistency and completeness. For experimental design, this study adopts a case analysis approach to compare the performance of a single LLM with that of the multi-source integration method across three dimensions: entity accuracy, relationship semantic consistency, and BOM hierarchical structural completeness.

Experimental results indicate that, compared with the single-LLM approach, the proposed multi-source integration combined with BOM structural constraints significantly reduces entity naming inconsistencies and relationship errors, effectively mitigates hierarchical disorder, and improves the overall quality of the knowledge graph. In conclusion, this study establishes a reproducible KG construction process with practical applicability, particularly suitable for multi-source data integration scenarios, and valuable for knowledge construction and management tasks involving hierarchical structures and complex relationships.

Keywords: Knowledge Graph, Large Language Model, Bill of Materials, Multi-source Data Integration, Structural Consistency.

誌謝

終於來到了論文最後一頁，也代表研究所旅程即將畫下句點。回顧這段時間，原本以為研生活會充滿壓力與挑戰，但實際走過後，發現這是一段充滿學習、成長與快樂回憶的旅程。這篇論文能夠順利完成，除了自己的努力之外，也要感謝一路上給予我幫助與陪伴的所有人。

首先，誠摯感謝我的指導教授楊達立教授。謝謝教授在研究過程中給予我專業的指導與建議，從研究方向、方法討論到論文修改，都提供許多寶貴意見。也感謝論文口試委員郭文宏教授與許洲榮教授，在百忙之中審閱本論文並提供建議，使本研究更加完整。

感謝我的家人，你們是我研究所期間最可靠的後盾。謝謝爸爸一直以來給予我的支持與幫助，讓我能安心完成學業；謝謝媽媽擔任我的「研究所美食補給站」，用一道道美味料理補充我的能量，雖然不一定了解我研究的內容，但始終知道寫論文的人一定要先吃飽。也謝謝姐姐帶我出國旅行，讓研生活不只有論文，也留下許多珍貴回憶。

感謝我的研究所好朋友們，謝謝你們陪伴我度過研究所生活中的每個階段。謝謝你們一起討論課業、分享想法，也願意接受我半夜突然發出的宵夜邀請，陪我聊天放鬆。因為有你們，研究所不只是完成學業的地方，也成為充滿歡笑與回憶的旅程。

特別感謝我的兩位「貓咪研究助理」——皮皮與花花。雖然你們沒有參與研究設計、整理資料或修改論文，但你們總是在自己的位置默默看著我。當你們覺得太久沒有被嚙時，便會用「喵喵喵」提醒我提供摸摸服務。謝謝你們用最簡單的方式陪伴我，成為研究所期間最可愛的遠端監督員。

最後，也想感謝一路努力完成研究的自己。謝謝自己保持對研究的熱情，願意探索未知、學習成長，並將腦中的想法化為一本真正完成的論文。研究所期間留下的，不只是研究成果，更是一段充滿收穫與快樂的回憶。

謹以此論文獻給所有支持、陪伴我的人，以及兩位沒有薪水、但要求很多的貓咪研究助理——皮皮與花花。

感恩的心，感謝有你。

目錄

摘要	i
Abstract.....	ii
誌謝	iii
目錄	iv
表目錄	vii
圖目錄	viii
第一章 緒論	1
1.1 研究背景	1
1.2 研究目的	3
1.3 研究貢獻	3
1.4 研究架構	4
第二章 文獻探討	6
2.1 大型語言模型與知識圖譜建構	6
2.1.1 實體與關係抽取研究	6
2.1.2 知識圖譜建構方法	7
2.2 知識圖譜品質與常見錯誤	8
2.2.1 實體抽取錯誤	8
2.2.2 關係錯誤與方向不一致	10
2.2.3 結構一致性與 schema 錯誤	11
2.3 物料清單與知識圖譜整合	12
2.3.1 物料清單結構與特性	12
2.3.2 物料清單與知識圖譜之對應關係	12
2.3.3 物料清單在資料整合與結構一致性中的角色	13
第三章 研究內容與方法	14
3.1 大型語言模型輔助之結構化資料生成方法	14

3.1.1 大型語言模型 JSON 生成流程	15
3.1.2 多來源 JSON 重組策略	18
3.1.3 多來源 JSON 集成與對齊	20
3.2 錯誤類型分析	23
3.2.1 實體抽取錯誤	23
3.2.2 關係語意與方向錯誤	24
3.2.3 結構與一致性錯誤	25
3.3 結構統整與一致化方法	26
3.3.1 實體正規化與去重複	26
3.3.2 關係處理與語意一致化	27
3.3.3 結構驗證與一致性檢核	28
3.4 知識圖譜建構與評估準則	29
3.4.1 知識圖譜建構流程	29
3.4.2 資料表示方式	29
3.4.3 人工驗證與評估準則	29
第四章 實驗結果與分析	31
4.1 資料集與實驗設計	31
4.2 評估方法與判定準則	32
4.3 實驗結果分析	32
4.3.1 短文本結果分析	32
4.3.2 長文本結果分析	33
4.3.3 整體比較分析	35
4.4 錯誤分析與案例討論	35
第五章 結論與未來展望	38
5.1 研究結果	38
5.2 實務應用展望	38
5.3 研究限制	39

5.4 未來研究方向	39
參考文獻	41
附錄一	46
Extended Abstract.....	48

國立虎尾科技大學



National Formosa University

表目錄

表 2.1、實體邊界錯誤示例	9
表 2.2、實體類型誤判示例	9
表 2.3、實體命名不一致與重複示例	10
表 3.1、關聯分類對照表	18
表 4.1、三種知識圖譜建構方法之實驗設定比較	31
表 4.2、短文本方法比較之 Precision、Recall 與 F1-score	33
表 4.3、長文本方法比較之 Precision、Recall 與 F1-score	34



National Formosa University

圖目錄

圖 1.1、LLM 輔助知識圖譜建構與品質改善流程示意圖.....	2
圖 1.2、本研究流程架構.....	5
圖 3.1、多來源 JSON 生成、重組與對齊之整體流程.....	15
圖 3.2、JSON 重組流程圖.....	20
圖 3.3、屬性語意向量建構與相似度計算示意圖	22
圖 4.1、短文本結果比較（共 100 筆）	33
圖 4.2、長文本結果比較（共 50 筆）	34
圖 4.3、案例一：本研究方法 BOM 層級結構圖	36
圖 4.4、案例二：單一 LLM 結合 BOM 層級結構圖.....	37
圖 4.5、案例二：本研究方法 BOM 層級結構圖	37

National Formosa University

第一章 緒論

1.1 研究背景

隨著人工智慧與資料驅動技術的快速發展，知識圖譜（Knowledge Graph, KG）已廣泛應用於資訊檢索、推薦系統、決策支援與智慧製造等領域。知識圖譜透過將實體（Entity）與其關係（Relation）以結構化方式表示為三元組（實體、關係、實體），能有效整合不同來源的資訊，並建立具語意關聯性的知識結構，以支援後續分析與應用[1]。相較於傳統資料表示方式，知識圖譜具備良好的可擴展性與可解釋性，因此逐漸成為智慧化系統中的重要核心技術。

然而，知識圖譜的建構過程仍面臨許多挑戰。傳統知識圖譜建構方法通常仰賴人工定義本體、資料標註與規則設計，不僅需要大量人力與時間成本，也難以因應資料規模快速成長及領域知識持續變化的需求[2]。此外，在多來源資料整合情境下，由於不同資料來源可能具有不同的表示方式與語意結構，容易導致實體命名不一致、關係定義衝突及結構設計不一致等問題，進而影響知識圖譜的品質與後續應用的可靠性[3]。

近年來，隨著大型語言模型（Large Language Model, LLM）的快速發展，研究者開始嘗試利用其語意理解與文本生成能力，協助進行知識圖譜中的實體與關係抽取，以降低人工建構負擔[4]。相較於傳統資訊抽取方法，LLM 具備較高的語意理解能力與跨領域適應性，能夠在語意複雜或描述不完整的情境下，自動生成結構化輸出，為知識圖譜的自動化建構提供新的可能性[5,6]。因此，如何結合 LLM 與知識圖譜建構流程，已逐漸成為相關研究的重要方向。

然而，LLM 的生成結果高度依賴輸入內容與模型內部推論機制，仍可能產生實體邊界模糊、命名不一致、關係語意錯誤及結構缺漏等問題[7,8,9]。特別是在多來源資料整合情境下，不同模型或不同輸入內容所生成的結果可能存在語意差異與結構衝突，進而造成知識圖譜中實體重複、關聯錯誤及層級混亂等現象，影響整體圖譜的語意一致性與結構完整性。因此，如何在利用 LLM 提升自動化效率的同時，維持知識圖譜的結構一致性與資料正確性，成為目前重要的研究課題。

為改善上述問題，本研究引入物料清單（Bill of Materials, BOM）結構作為知識表示與資料整合基礎。BOM 具備明確的父子層級與組成關係，可有效描述實體之間的結構依賴性與組成邏輯，因此適合作為多來源資料整合與結構一致化的依據。本研究利用 BOM 結構對 LLM 所生成的 JavaScript Object Notation（JSON）資料進行重組與整合，以降低實體重複、關聯錯誤及層級衝突等問題，進一步提升知識圖譜的語意正確性與結構完整性。

綜合上述，本研究旨在結合 LLM 自動抽取能力與 BOM 結構化方法，建立一套多來源資料整合與知識圖譜建構機制，以降低人工建構成本，並提升知識圖譜的建構品質與可擴展性。圖 1.1 顯示本研究所關注之 LLM 輔助知識圖譜建構與品質改善流程示意，涵蓋文本輸入、JSON 與 BOM 生成、多來源整合，以及知識圖譜建構與品質評估等階段。




圖1.1、LLM 輔助知識圖譜建構與品質改善流程示意圖

1.2 研究目的

本研究旨在探討如何結合 LLM 與 BOM 結構，建立一套兼具語意完整性與結構正確性的知識圖譜建構方法。針對多來源資料整合過程中可能產生的語意不一致、關聯錯誤與層級衝突等問題，本研究從資料整合與結構約束的角度進行分析與方法設計。在應用層面，知識圖譜作為連結實體、事件與 BOM 結構的重要基礎，其語意品質與結構合理性將直接影響後續分析、決策支援與系統應用的可靠性。然而，LLM 所生成的 JSON 與 BOM 結構，可能因模型差異而產生實體定義不一致、關係語意模糊或層級錯誤等問題。若缺乏有效的整合與驗證機制，將難以確保知識圖譜的品質與實務可用性。

基於上述動機，本研究以知識圖譜建構與 BOM 層級應用為研究範圍，透過多來源結構化資料之整合與分析，探討 LLM 輔助建構流程中的關鍵問題，並提出結構統整與一致化方法。具體研究目的如下：

1. 提升知識圖譜整合的準確性與一致性：
透過設計多 LLM 結果的整合與對齊機制，比對並融合不同模型所生成的 JSON 結構，以降低單一模型可能產生偏誤，提升整體知識圖譜的準確性與一致性。
2. 實體對齊、關係一致化與結構驗證：
針對多來源資料中可能出現的實體重複、關係語意不一致及結構錯誤問題，進行實體正規化、關係語意映射及結構一致性檢核，以確保知識圖譜及 BOM 層級的完整性與正確性。
3. 建立 BOM 結構約束的知識圖譜建構方法：
以 BOM 層級作為知識圖譜的結構骨架，透過其階層與組成關係，作為知識圖譜建構過程中的結構約束機制，以提升整體圖譜的層級一致性與邏輯正確性。

綜合而言，本研究透過多來源資料整合、結構約束與品質分析方法的設計，期望提升 LLM 輔助知識圖譜建構的可靠性與實務應用價值，並提供一套具可重現性的知識圖譜建構流程。

1.3 研究貢獻

本研究的主要貢獻如下：

1. 提出結合 BOM 結構約束與多來源 LLM 結果整合的知識圖譜建構方法，透過將 BOM 層級與組成關係納入建構過程，並整合多模型生成結果，有效提升知識圖譜在語意一致性與結構完整性上的穩定性。
2. 設計多 LLM 生成結果的整合與一致化機制，透過實體對齊、關係映射與決策策略，有效降低不同模型輸出的語意差異與結構衝突。
3. 建立多層級知識圖譜品質評估方法，從實體一致性、關係語意一致性與結構完整性等面向進行系統性分析，以驗證所提出方法的有效性。
4. 建構結合多來源資料整合與 BOM 結構約束的知識圖譜建構流程，提供一套具可重現性與實務應用價值的方法架構。

1.4 研究架構

本研究的研究架構如圖 1.2 所示，整體流程以知識圖譜建構過程中的語意不一致與結構不完整問題為核心。首先，透過研究背景與文獻探討，分析 LLM 於知識圖譜建構中的應用現況，並整理既有研究在實體抽取、關聯建構與 BOM 層級表示上的限制，以建立本研究的研究動機與問題意識。

在方法設計上，本研究透過提示詞引導 LLM 生成 JSON 結構資料，並針對同一文本使用多個不同 LLM 進行生成，以取得多組結構化結果。接著，進行多來源 JSON 的整合與一致化處理，包括實體正規化、關係語意處理與 BOM 結構驗證等機制。其中，BOM 不僅作為知識表示形式，同時亦作為結構約束依據，用以檢查實體之間的父子層級與組成邏輯，以提升知識圖譜的語意完整性與結構一致性。

最後，本研究以 LLM 生成的短文本與長文本資料進行實驗，並比較單一 LLM、單一 LLM 結合 BOM，以及本研究提出的多來源 LLM 結合 BOM 方法的差異。評估內容涵蓋實體一致性、關係一致性、結構正確性與結構完整性等面向，並以本研究方法經人工檢視後的結果作為參考基準，分析不同方法於語意與結構層面的表現差異。此外，本研究亦透過錯誤分析與案例討論，進一步驗證所提出方法在提升知識圖譜品質與 BOM 結構一致性上的有效性。




圖1.2 、本研究流程架構

第二章 文獻探討

本章針對本研究相關的文獻進行探討，說明大型語言模型應用於知識圖譜建構的研究發展，以及知識圖譜在建構過程中所面臨的品質與錯誤問題。首先，彙整近年來文字資料轉換為知識圖譜的相關研究，說明實體與關係抽取技術以及知識圖譜建構方法的演進。其次，整理既有研究中對知識圖譜品質的評估觀點與常見錯誤類型，包括實體抽取錯誤、關係語意與方向不一致，以及結構一致性與 schema 相關問題。此外，亦探討物料清單 BOM 等結構化資料在知識圖譜建構中的應用，特別是在其在層級表示、資料整合與結構一致性上的輔助角色。透過文獻回顧，釐清現有研究的成果與限制，作為本研究方法設計與錯誤分析架構建立的基礎。

2.1 大型語言模型與知識圖譜建構

隨著自然語言處理技術的發展，文本資料中所蘊含的知識逐漸被轉換為結構化形式，以支援知識推論、檢索與決策分析[10]。知識圖譜作為一種以實體與關係為核心的知識表示方式，已廣泛應用於搜尋引擎[11]、推薦系統[12]與問答系統[13]等領域。早期知識圖譜建構多仰賴規則式或傳統機器學習方法[14]，近年來隨著大型語言模型的出現，文字轉換為知識圖譜的方式逐漸朝向更具語意彈性與自動化的方向發展[15]。

2.1.1 實體與關係抽取研究

實體與關係抽取（Entity and Relation Extraction）是知識圖譜建構過程中一個至關重要的基礎步驟，也是將非結構化文本轉換為圖結構知識表示的核心技術之一。其主要目的是從非結構化或半結構化的資料中辨識出具語意意義的實體，同時判定這些實體之間的關係，以生成可以支持推論與分析的結構化知識表示。相關研究顯示，實體與關係抽取的準確度直接影響著知識圖譜的整體品質與應用效果[16]。

早期的實體與關係抽取研究多採用規則式方法（rule-based method）或傳統機器學習模型，這些方法通常依賴於人工設計的語法規則、詞彙特徵和統計模型來進行命名實體識別（Named Entity Recognition, NER）[17]與關係抽取（Relation Extraction, RE）[18]。例如，生物醫學領域中的許多工作一致表明，儘管這類方法在特定領域內能達到穩定表現，但在面對語意多樣或語境複雜的資料時，難以保持良好的泛化能力[16]。

隨著深度學習技術的迅速發展，研究者們開始引入神經網絡模型來提升實體與關係抽取的表現[19]。特別是循環神經網路（Recurrent Neural Network, RNN）、長短期記憶網路（Long Short-Term Memory, LSTM）和卷積神經網路（Convolutional Neural Network, CNN）等模型都在這一過程中發揮了重要作用[20]，能夠透過分散式語意表示來增強對上下文的理解[21]。這些方法的運用不僅降低了人工特徵設計的需求[22]，也提高了抽取結果在語意層面的準確性。

近年來，以大型預訓練語言模型為代表的 LLM 架構，因其出色的語意理解與生成能力，逐漸被應用於實體與關係抽取的任務中。相對於傳統模型，LLM 能夠在僅有少量樣本提示（Few-Shot）或零樣本提示（Zero-Shot）的情況下，直接生成結構化的輸出[23]，這為知識圖譜的自動化建構提供了新的潛力[24]。研究表明，LLM 在處理語意模糊或描述不完整的文本時，相較於傳統方法展現出優越的適應能力[25]。

儘管 LLM 在實體與關係抽取中展現了顯著的潛力，但也有研究指出，LLM 生成的結果高度依賴於輸入提示的設計和模型的內部推論機制[26]，這在實際應用中可能導致實體邊界定義不一致、實體命名不統一及關係語意錯誤等問題[27]。此外，模型生成的結果未必符合既定的知識圖譜結構或 schema 規範，可能造成結構一致性與可用性上的風險[24]。因此，針對 LLM 輔助的實體和關係抽取進行系統性的品質分析與錯誤歸納，成為當前知識圖譜建構研究中的一項重要課題。

綜合上述研究可知，雖然 LLM 為實體與關係抽取提供了新的技術途徑，但其生成結果在準確性與結構一致性方面仍存在顯著不確定性。現有研究多著重於方法效能的比較，較少針對 LLM 輔助抽取結果於知識圖譜建構流程中的錯誤類型與品質影響進行系統性分析。因此，如何系統性分析 LLM 輔助實體與關係抽取在知識圖譜建構流程中所產生的錯誤類型，並評估其對整體圖結構與應用品質的影響，仍有進一步探討的必要。

2.1.2 知識圖譜建構方法

在完成實體與關係抽取後，將抽取結果轉換為具結構性與可推論性的知識圖譜，是知識圖譜建構流程中關鍵環節[28]。知識圖譜的建構涉及實體節點的建立、關係邊的定義，以及圖結構和 schema 的設計[29]。其目的在於將零散且異質的抽取結果整合為語意一致、結構明確且具擴充性的知識表示形式。

早期的知識圖譜建構常以人工設計的本體（ontology）或 schema 為核心方式[30]。透過預先定義實體類型、關係種類及屬性約束，將抽取結果對應至既定語意結構中。這類方法能確保圖結構在語意和層級上的一致性，並有助於後續查詢與推論與知識一致性維護[31]。然而，高昂的建構成本以及對新領域或資料分布變化的適應困難，限制了其可擴展性與靈活性[32]。

針對資料規模的擴大與應用需求的多樣化，研究者開始提出自動化或半自動化的知識圖譜建構方法[33]，旨在降低人工干預程度。這些方法通常結合抽取結果與圖結構生成策略，將實體視為節點、關係視為邊，直接構建三元組（subject - predicate - object）形式的圖結構[34]。部分研究進一步引入實體對齊（entity alignment）與實體消歧（entity disambiguation）機制，以提升不同資料來源下圖結構的整合品質。

隨著 LLM 的快速發展，知識圖譜建構方法逐漸演進為以語言模型輔助的方向。與傳統流程需分別執行實體抽取、關係抽取與結構映射不同，LLM 能透過提示設計（prompting），直接從文本生成符合知識圖譜格式的結構化輸出，如三元組或子圖結構[5]。然而，此類輸出多依賴模型內部語意推論，未必能保證與既有知識圖譜結構或應用情境的一致性。相關研究顯示，此方法在處理語意複雜或描述不完整的資料時，展現出更高的彈性與適應能力，並加速了知識圖譜建構的流程。

儘管 LLM 輔助的知識圖譜建構方法具潛力，但仍然面臨結構與品質層面的挑戰。模型生成結果並非總是遵循既定 schema，可能會導致關係類型不一致、節點層級混亂或圖結構冗餘等問題。此外，不同提示設計或生成策略所導致的圖結構變異，進一步增加了知識圖譜在穩定性與可重現性上的風險。因此，在保留 LLM 彈性的同時，如何確保知識圖譜結構的一致性與可用性，成為當前研究的重要議題[35]。

綜合上述分析，知識圖譜建構方法已由早期以人工本體為核心的設計，逐步發展為結合自動化抽取與大型語言模型輔助的多元流程。儘管 LLM 提供了高度的彈性與生成能力，但其在結構一致性與結果穩定性方面仍存在不足。因此，如何在維持語言模型彈性的同時，引入適當的結構約束機制，以提升知識圖譜的語意準確性與結構一致性，成為本研究關注的核心問題。本研究進一步透過多模型整合與結構約束方法，探討其對知識圖譜建構品質的影響。

2.2 知識圖譜品質與常見錯誤

在知識圖譜的建構過程中，維持高品質是確保其可用性與實務應用成效的關鍵。即便在實體與關係的抽取階段取得良好準確率，若後續建構過程中出現結構不一致、語意錯誤或 schema 不符等問題，仍將削弱知識圖譜對查詢與推論任務的支援能力。因此，系統性分析知識圖譜建構過程中的品質問題，成為當前研究的重點之一。

知識圖譜的品質問題往往源於多個階段的累積影響。首先，實體與關係的抽取過程固有的不確定性可能導致錯誤數據的產生[36]。Nananukul 等人指出，異質資料整合過程中的對齊誤差，加劇了這些問題的產生[37]。其次，知識圖譜建構時未能嚴格遵循既定的 schema 與語意約束，這導致整體語意一致性和推論可靠性受損[38]。

這些品質問題不僅影響單一節點或關係的正確性，更可能在整體圖結構內產生連鎖效應。在現有知識圖譜構建方法中，捕捉結構一致性與維持語意連貫性仍是核心挑戰，尤其在多源融合與語義匹配過程中，由於 schema 差異與語義不一致等問題，現行技術尚無法完全保障知識圖譜的結構連貫性[39]。這種累積的連鎖效應會進一步影響知識圖譜的整體效能。

傳統上，以人工介入或基於規則的方式建構知識圖譜的方法在結構穩定性上表現良好。然而，這類方法仍會面臨抽取錯誤或資料覆蓋不足的問題，導致知識表述不完整或偏誤[40]。隨著自動化與資料驅動方法的興起，在實體層級及關係層級的錯誤類型（如實體邊界錯誤、實體類型誤判）分析逐漸受到重視，這些問題無疑加深了知識圖譜建構的複雜性[41]。

最近的研究強調，使用 LLM 輔助的知識圖譜建構方法在效率和語意理解能力上具有顯著優勢。然而，這也帶來了知識圖譜品質的新挑戰，如實體命名的不一致、關係類型的混用和不合理的圖結構配置等[42]。研究發現，LLM 的生成結果高度依賴提示設計與模型內部推論機制，使得其結構化輸出在一致性與可重現性方面仍存在不穩定風險[43]。

綜合相關研究可知，知識圖譜品質問題不僅涉及單一錯誤事件的發生，更反映了建構流程中結構設計、語意建模與自動化生成之間的張力。因此，有必要從實體層級、關係層級與整體結構層級，系統性地整理知識圖譜建構過程中常見的錯誤類型與品質風險。基於此，本節將進一步彙整並說明既有文獻中對於實體抽取錯誤、關係錯誤以及結構一致性與 schema 問題的相關探討，作為後續錯誤分析與實證研究的基礎。

2.2.1 實體抽取錯誤

在知識圖譜的建構流程中，實體抽取錯誤被認為是最常見且基礎的品質問題之一。這些錯誤主要發生於實體辨識與實體類型判定階段，不僅會影響單一實體的準確性，還可能

對後續的關係建構和推論過程造成長期影響[44]。在本節中，我們將詳細討論實體邊界錯誤、實體類型誤判以及實體命名不一致等多種實體抽取錯誤類型，並探討它們如何影響知識圖譜的整體品質。

實體邊界錯誤指的是模型未能正確判定實體的起訖範圍，例如將多詞組成的專有名詞拆分為多個獨立的實體，或將不具完整語意的詞彙誤判為實體。這類錯誤在資料中句法結構複雜或專業術語頻繁出現的情況下尤為明顯，進而影響了實體的識別正確率。例如，Wu 等人指出，在區塊鏈物聯網的應用中，實體邊界的錯誤生成將導致威脅情報的提取受到影響[45]。同樣地，Xu 等人指出，在研究中國電子病歷中也觀察到，因為缺乏明確的詞邊界，導致許多醫療術語無法被準確識別，從而影響了實體抽取的效果[46]。

表 2.1、實體邊界錯誤示例

句子	正確實體邊界	錯誤實體邊界	影響
Apple 公司發布新 iPhone	Apple 公司 / 新 iPhone	Apple / 公司 / 新 / iPhone	導致實體過度拆分，降低實體識別的完整性與準確度
區塊鏈物聯網應用	區塊鏈物聯網	區塊鏈 / 物聯網	複合實體被拆分，造成語意資訊不完整
高血壓病史記錄	高血壓病史	高血壓 / 病史	專業術語邊界錯誤，影響醫療語意理解與後續應用

實體類型誤判是另一種常見的實體抽取錯誤。當模型僅依賴上下文語意進行推論，而缺乏明確類型約束時，可能會將實體指派至不當的語意類別。例如，在醫學領域中，如果設備名稱被誤標為事件，或組織名稱被錯誤地詮釋為地點，則後續的推論可能會出現偏差[47]。在 LLM 輔助的抽取方法中，這類錯誤因模型生成的彈性而變得更加明顯。這些模型可能根據多樣的上下文生成不一致或不準確的類型提醒，結果導致類別判定錯誤的發生。

表 2.2、實體類型誤判示例

句子	正確實體類型	錯誤實體類型	影響
Apple 公司發布新 iPhone	Apple 公司 → 組織	Apple → 水果	語意一致性破壞，查詢失效
巴黎是法國首都	巴黎 → 地名	巴黎 → 人名	地理知識錯誤，推理失準
Amazon 推出雲端服務	Amazon → 公司	Amazon → 河流	商業知識抽取錯誤

實體命名不一致與重複實體是影響知識圖譜一致性的重大問題。當相同概念以不同命名形式出現時，將會導致節點冗餘以及語意分裂，從而對後續查詢和推論結果產生偏差。例如，當一個實體在不同文獻中以不同形式命名時，這會引發冗餘實體的問題，進一步影

響整體知識圖譜的語意完整性[48]。研究指出，實體識別的準確性對於構建一個高效的知識圖譜至關重要，而不一致的命名則會削弱其存取信息的完整性和推論可靠性[49]。

表 2.3、實體命名不一致與重複示例

類型	例子	影響
命名不一致	IBM / International Business Machines / IBM 公司	查詢結果分散，語意不一致
實體重複	COVID-19 / 新冠肺炎 / 武漢肺炎	實體冗餘，推理錯誤
跨語言不一致	北京 / Peking / Beijing	多語言融合困難，降低可用性

綜合上述研究可知，實體抽取錯誤可概括為實體邊界錯誤、實體類型誤判與實體命名不一致三大類型，且此類錯誤往往具有累積與放大效應，容易在知識圖譜建構流程中逐步擴散，進而影響後續關係建構、圖結構一致性與應用成效。因此，對實體抽取錯誤進行系統性的分類與分析，並評估其對知識圖譜整體品質的影響，對於提升 LLM 輔助知識圖譜建構之可靠性與實務可用性具有重要意義，也為後續錯誤分析與實證研究奠定基礎。

2.2.2 關係錯誤與方向不一致

在知識圖譜中，關係（relation）用以描述實體之間的語意連結，其正確性對於整體圖結構的可解釋性與推論能力具有關鍵影響[29]。相比於實體錯誤多集中於節點層級，關係錯誤則直接影響實體之間的連結方式，一旦處理不當，容易導致知識圖譜產生語意扭曲或推論結果偏誤[49]。因此，關係抽取與關係建構階段的品質問題被視為知識圖譜品質管理中的核心挑戰之一[50]。

關係錯誤中最常見的類型之一為關係類型誤判，其指的是模型在已正確識別實體對的情況下，將其語意關係錯誤指派為不恰當的關係類型。例如，將「設備—製造商」的關係錯誤標記為「使用於」，或將具因果語意的關係誤判為單純的時序關係，皆可能導致後續語意推論產生系統性偏差[51]。相關研究指出，此類錯誤多源於語境資訊不足、關係定義不明確，或不同領域中對相同語意關係的表述差異，進而提高模型判斷的不確定性[52,53]。

在自動化與資料驅動的關係抽取環境中，模型對語句結構與語意角色的理解能力亦會影響關係判定的穩定性。即使在採用 LLM 的情況下，其關係抽取結果仍高度依賴提示設計與生成策略；若提示未能明確約束關係語意或方向性，模型可能生成語意混淆或不一致的關係描述，進而增加關係類型誤判的風險[54]。

另一類具高度破壞性的錯誤為關係方向不一致[32]。此類問題通常發生於具方向性的關係（如「包含」、「隸屬於」、「導致」等），當主詞與受詞的語意角色被顛倒時，即使關係類型本身正確，仍會造成語意解讀上的嚴重錯誤。例如，將「公司—生產—產品」錯誤建構為「產品—生產—公司」，這會導致推論結果與現實語意相悖[51]。Hogan 等人指出，方向性錯誤會嚴重影響知識圖譜在查詢與規則推論任務中的可靠性[29]。

值得注意的是，關係錯誤往往具有明顯的擴散效應。一旦錯誤的關係被納入知識圖譜中，後續基於該關係進行的推論、路徑搜尋或結構分析皆可能受到影響，甚至放大原始錯誤對整體圖結構的影響範圍。Xue 與 Zou 指出，相較於單一實體錯誤，關係層級的錯誤往往更不易被察覺，但其對知識圖譜語意一致性與推論穩定性所造成的長期影響卻更加顯著[55]。

在關係建構方法方面，傳統監督式模型可透過大量標註資料學習相對穩定的關係模式，但在跨領域或語境差異較大的應用情境下，仍容易出現關係類型誤判與方向錯置的問題。相較之下，LLM 輔助的關係抽取方法雖具備較強的語意理解能力與彈性，卻也引入了關係定義不一致與結構不穩定等新的品質風險[54]。

綜合上述分析，關係錯誤與方向不一致問題不僅影響實體間的局部連結，更可能破壞知識圖譜整體的語意結構與推論邏輯。在 LLM 輔助的知識圖譜建構過程中，如何在保留模型語意彈性的同時降低關係類型誤判與方向錯置的風險，成為提升知識圖譜品質的重要課題。因此，對於關係抽取錯誤進行系統性的分類與分析，對於後續結構品質評估與錯誤修正機制的設計，具有關鍵基礎意義。

2.2.3 結構一致性與 schema 錯誤

在知識圖譜的構建過程中，結構一致性與 schema 正確性是確保圖譜可擴展性、可推論性及長期維護能力的關鍵因素。schema 不僅規範了實體類型與關係類型的定義，還隱含了實體間可允許的連結方式與語意約束。當知識圖譜未能嚴格遵循既定的 schema 時，可能導致整體圖結構出現語意衝突或推論失效，從而影響整體質量和效能。

結構一致性錯誤多表現在實體層級與關係層級的組合違規[32]。例如，若 schema 中明確定義「設備」僅能透過「由…製造」連結至「製造商」，但實際結構中卻出現「設備—隸屬於—組織」等不合理關係，將直接影響圖結構的語意一致性[56]。這種錯誤往往不易在局部抽取階段被察覺，卻可能在查詢或推論階段顯著影響結果正確性。

延續上述結構違規問題，研究亦指出，當知識圖譜未能恰當遵循 schema 規範時，往往會進一步衍生多重邏輯錯誤[38]。因此，在設計與建構階段中，應仔細檢視實體與關係的規範，以提升抽取階段結果的正確性與一致性[57]。例如，已有研究指出，在不同資料來源融合時，若未能進行有效的 schema 對齊或實體對齊，可能導致同一實體在不同來源中呈現多重角色或被賦予不一致的關係定義，從而影響知識圖譜整體的穩定性與可用性[58]。

在此情況下，schema 不一致問題將直接削弱知識圖譜於結構推論與語意理解層面的穩定性。尤其在自動化的知識圖譜建構流程中，各資料集常採用不同的概念分類方式與關係定義，於多源資料融合或跨領域應用場景下，若未能進行有效的 schema 整合或實體對齊，將難以保證語意結構的一致性，並進一步影響知識圖譜表示與建構流程的整體穩定性與可用性。相關研究指出，這類不一致性會加劇知識圖譜在結構推論和語意理解上的不穩定性，增加查詢與推論中出現錯誤的風險[49]。

傳統的規則式或人工建構方法雖能在 schema 遵循上維持較高的一致性，但其擴展性與建構效率有限。在自動化與資料驅動的知識圖譜建構流程中，尤其在 LLM 輔助的情境下，生成結果往往基於語意合理性而非嚴格格式約束，缺乏明確的 schema 驗證機制，容

易產生表面合理但不符合 schema 定義的結構。相關研究指出，這類結構性錯誤不僅會降低知識圖譜的準確性，還可能影響後續資料查詢與推論的可靠性[59]。

綜合而言，結構一致性與 schema 錯誤在知識圖譜建構中屬於高層級但影響深遠的品質問題。這類錯誤不僅難以透過單一實體或關係檢查進行修正，亦可能在整體知識圖譜結構中累積並放大其影響，進而削弱知識圖譜在推論與應用層面的可靠性。因此，如何在自動化建構流程中有效維持 schema 一致性，並及早識別與修正結構層級的錯誤，已成為當前知識圖譜品質管理與評估中的重要課題[42]，亦凸顯對實際建構流程中結構錯誤進行系統化分析的必要性。未來的研究應聚焦於改進資料整合策略，以提升知識圖譜的結構一致性與 schema 正確性。

2.3 物料清單與知識圖譜整合

在知識圖譜建構過程中，如何有效表達實體之間的層級關係與組成結構，是影響圖譜品質的重要因素。傳統知識圖譜多以三元組作為基本表示方式，用於描述實體之間的語意關聯。然而，由於 RDF 資料模型主要基於三元組結構並以二元關係為核心，在表達多層級結構或複雜組成關係時，通常需要額外的建模機制加以補充[60]。

BOM 作為描述產品組成與階層關係的結構化資料，被廣泛應用於產品設計與製造管理領域。其具備明確的父子關係與層級特性，能有效呈現產品結構中的組成關係。透過將 BOM 與知識圖譜結合，可強化實體之間的組成關係表示，並作為多來源資料整合與結構驗證的參考依據。此外，知識圖譜可將異質資料整合於統一語意模型中，避免資訊孤島並支援後續推理與一致性驗證[61]。

因此，本節將探討 BOM 的結構特性、其與知識圖譜之對應關係，以及在資料整合與結構一致性中的應用角色。

2.3.1 物料清單結構與特性

BOM 是一種用於描述產品組成結構的資料表示方式，廣泛應用於製造、產品設計及資源管理等領域。其主要功能在於定義產品由哪些元件所構成，以及各元件之間的層級關係。BOM 通常以階層式結構呈現，包含父子組件關係，並可延伸為樹狀或有向無環圖（Directed Acyclic Graph, DAG）形式，以描述複雜產品的多層級組成。

在資料特性上，BOM 具有明確的結構性與層級性，其節點對應於產品或組件實體，而邊則表示組成或包含關係[62]。相較於非結構化文本資料，BOM 提供較為穩定且可預測的資料模式，使其在資料整合與結構建模中具有重要價值。此外，BOM 通常包含屬性資訊（如數量、規格或版本），可進一步擴展為多維度的結構化資料表示[63]。

由於 BOM 本身即具備實體與關係的結構化特性，因此在概念上與知識圖譜中以節點與邊表示實體關係的方式具有高度相似性，為後續整合提供良好的基礎。

2.3.2 物料清單與知識圖譜之對應關係

基於 BOM 所具備的結構化特性與層級關係，其資料表示方式可與知識圖譜進行對應與轉換。知識圖譜主要由節點與關係構成，並透過三元組描述實體之間的語意關聯[39]。

由於 BOM 同樣用於描述產品與組件之間的組成關係，因此兩者在資料表示上具有良好的對應基礎。

在對應關係上，BOM 中的產品或組件可映射為知識圖譜中的實體節點，而其父子組件關係則可轉換為圖中的關係邊，例如「包含 (hasComponent)」或「組成於 (partOf)」等語意關係。此外，BOM 所呈現的階層結構亦可反映於知識圖譜的拓撲結構，使圖譜具備多層級的語意表示能力，而不僅限於平面關聯。

透過上述映射方式，原本以階層式或表格形式存在的 BOM 資料，得以轉換為知識圖譜形式的結構化表示，進而支援語意關聯分析與推論。然而，在實際應用中，仍可能面臨命名不一致、層級定義差異或關係語意模糊等問題，因此需搭配適當的正規化與對齊機制，以確保轉換後的知識圖譜能正確反映原始資料語意。

2.3.3 物料清單在資料整合與結構一致性中的角色

在多來源資料整合的情境下，知識圖譜建構過程中常面臨實體重複、關係語意不一致及結構衝突等問題，進而影響整體圖譜的品質與可用性。特別是在透過 LLM 生成結構化資料（如 JSON 或三元組）時，不同模型或不同生成結果之間可能存在命名差異、關係定義不一致或層級資訊缺失等情形，使得後續整合與分析更加困難。

在此情境下，BOM 作為具備明確層級與組成關係的結構化資料，可在知識圖譜建構過程中扮演重要的輔助角色。首先，BOM 可作為結構骨架，提供實體之間的層級參考，使知識圖譜在建構過程中能維持合理的階層關係，避免出現關聯錯置或層級混亂的問題；其次，BOM 可作為資料整合與實體對齊的依據，透過其所定義的組件關係，輔助判斷不同來源資料中的實體是否屬於相同組成結構，進而減少實體重複與關係錯誤的情形，提升整體整合的一致性；此外，BOM 亦可用於結構一致性檢核，例如檢查是否存在不合理的組成關係、層級斷裂或循環關係等問題，以確保知識圖譜符合既定的結構規範。

綜合而言，BOM 不僅可作為知識圖譜的結構參考，亦可在資料整合與品質控制過程中提供重要支援。透過將 BOM 與 LLM 生成的結構化結果進行整合，有助於提升知識圖譜在層級表示、資料一致性及結構正確性方面的整體表現，並作為後續方法設計與實驗分析的基礎。

第三章 研究內容與方法

本章說明研究的內容與方法，重點在於描述透過 LLM 生成結構化資料（JSON）的流程設計，並進一步說明多個 LLM 生成結果的整合方法，以及知識圖譜建構過程中錯誤類型的定義、分析與修正方式。整體方法依序涵蓋結構化資料生成、結果整合、錯誤判定、結構統整與品質評估等步驟，以系統性方式建構具語意一致性與結構完整性的知識圖譜。其中，JSON 結構同時包含實體、關聯及 BOM 層級資訊，關聯用以描述實體之間的語意關係，而 BOM 則用以呈現父子層級結構，以保留完整的結構資訊。

3.1 大型語言模型輔助之結構化資料生成方法

在知識圖譜建構過程中，如何將原始資料轉換為結構化表示，是影響後續分析與整合品質的重要關鍵。本研究透過 LLM，將不同形式的資料轉換為統一格式的 JSON 結構，作為知識圖譜建構基礎。該 JSON 輸出同時包含實體、關聯及 BOM 層級資訊，用以描述實體之間的語意關係與組成結構。此外，為降低單一模型可能產生的偏差，本研究採用多個 LLM 對相同資料進行生成，並將多份結果進行整合，以提升整體資料品質與一致性。為說明研究的整體方法流程，其處理架構如圖 3.1 所示。






圖3.1、多來源 JSON 生成、重組與對齊之整體流程

本節後續將分別說明 JSON 生成流程、BOM 結構設計，以及多 LLM 結果整合方法。

3.1.1 大型語言模型 JSON 生成流程

本研究採用 LLM 將自然語言描述轉換為結構化資料，輸出包含實體 (Entities)、關係 (Relations) 以及 BOM 的 JSON 格式，以作為後續知識圖譜建構與資料整合的基礎。為使生成結果符合預期結構，本研究透過提示詞設計 (prompting) 將結構化規則嵌入 LLM 生成流程中，使模型在生成階段即符合知識圖譜與 BOM 結構的需求。本研究所使用的提示詞設計詳見附錄一，以確保方法的可重現性。整體流程如下：

1. 角色與規則設定：

透過提示詞設定 LLM 角色為「知識圖譜解析器」與「物料清單解析器」，明確定義輸入為自然語言描述，輸出為結構化 JSON。同時，於提示詞中規範模型需將語意資訊與結構資訊同步建構，包含將動詞轉換為關係表示，並建立 BOM 結構與實體節點的對應關係，以確保組成結構與語意關聯之間的一致性。

2. JSON 結構規範：

本研究定義統一的 JSON 輸出格式，包含三個主要部分：

- (1) Entities：實體節點陣列，每個節點包含唯一識別碼（ID）、名稱（Name）、分類（Category）、詞性（Part-of-Speech, Pos）以及屬性（Properties）等資訊，用以描述知識圖譜中的基本單位。
- (2) Relations：語意關係陣列，描述實體之間的語意關係，每筆關係包含起點（Source）、終點（Target）及關係名稱（Relation），並可附加順序（Seq）、問句標記（Question）及其他屬性資訊，用以表達事件流程或語意連結。
- (3) BOM：物料清單結構，以樹狀或 DAG 形式呈現產品的組成關係，每個節點包含 ID、數量（Qty）、單位（Unit）與子節點（Children），用以明確表示父子層級關係與組成結構。

此外，提示詞中亦規範數量資訊與單位的表示方式，並要求輸出格式符合 JSON 結構，以確保資料的一致性與可解析性。

例如，以「醬汁由麻油、醬油和米酒以一比一比一的比例調製」為例，其對應的 JSON 節錄如下，可見同一組成關係在三個部分中的不同表示方式：

```
"Entities": [  
  {"ID": "醬汁", "Name": "醬汁", "Category": ["組件"], "Pos": "名詞",  
    "Properties": [{"Name": "組成比例", "Value": "麻油:醬油:米酒=1:1:1"}]},  
  {"ID": "麻油", "Name": "麻油", "Category": ["材料"], "Pos": "名詞", "Properties": []},  
  {"ID": "醬油", "Name": "醬油", "Category": ["材料"], "Pos": "名詞", "Properties": []},  
  {"ID": "米酒", "Name": "米酒", "Category": ["材料"], "Pos": "名詞", "Properties": []}  
],  
"Relations": [  
  {"Source": ["醬汁"], "Target": ["麻油", "醬油", "米酒"], "Relation": "調製"}  
],  
"Bom": [  
  {"ID": "醬汁", "Qty": "1", "Unit": "份",  
    "Children": [{"ID": "麻油", "Qty": "1", "Unit": "份", "Children": []},  
    {"ID": "醬油", "Qty": "1", "Unit": "份", "Children": []},  
    {"ID": "米酒", "Qty": "1", "Unit": "份", "Children": []}]  
]
```

由此可見，Relations 以語意連結（「調製」）呈現組成關係，並可承載比例等描述性資訊；BOM 則以顯式父子結構呈現層級組成。兩者分別對應語意與結構兩個面向，共同構成完整的知識表示。

3. 生成策略：

為提升生成結果的穩定性與結構品質，本研究採用以下策略：

- (1) 自然語言轉換：透過提示詞引導 LLM 將輸入的自然語言描述轉換為符合規範的 JSON 結構。
- (2) 數量資訊處理：當文本中包含數量描述時，將其轉換為對應的數量資訊，並以屬性或結構方式與相關實體建立關聯。
- (3) 結構對應機制：將 BOM 結構與 Entities 節點進行對應，確保組成關係與層級

資訊在不同表示之間保持一致。

- (4) 多模型生成策略：考量 LLM 在生成過程中具有隨機性，且不同模型或不同次生成可能產生差異，本研究採用多來源生成策略，透過多次生成或不同模型生成結果，以提升資料多樣性與覆蓋率，作為後續重組與整合的基礎。
- (5) 關係抽取原則：僅保留動詞或具語意的關係詞作為 Relations，以避免將描述性資訊轉換為冗餘關係，提升關係表示的準確性與一致性。
- (6) 關係語意標準化：本研究不依關係詞表面文字（如「包含」、「組成」）判斷是否對應 BOM，而是依 3.1.2 的關聯語意分類機制判定：凡歸類為 Detail 類型且對應的父子關係已存在於 BOM 結構者，視為組成關係；其餘則視為一般語意描述。
- (7) 結構表示策略：屬性中可包含上層節點與層級等資訊，但此類資訊屬於描述性資料，需額外解析方能還原結構；本研究透過 BOM 以顯式方式表示父子關係，使組成結構具備更高的可讀性與可運算性。

4. 輸出與驗證

- (1) 資料輸出：LLM 所生成的 JSON 結果，將直接作為後續資料重組、實體對齊與知識圖譜建構的輸入。
- (2) 結果驗證與迭代修正機制：

為確保生成結果可供後續處理，本研究以「是否能成功解析為內部資料物件」作為基本驗證依據。當生成結果無法通過解析（如 JSON 格式錯誤或無法轉換為對應物件）時，系統將產生錯誤訊息並進行修正流程。

除基本解析驗證外，本研究亦進一步設計結構一致性檢查規則，包含：

- BOM 節點的 ID 必須存在於 Entities 節點中。
- Relations 中的 Source 與 Target 必須對應至 Entities 節點。
- BOM 節點的 Unit 不可為空值。

當上述任一條件不符合時，系統將產生對應的錯誤訊息，並將錯誤訊息連同原始提示詞與輸入資料回饋至 LLM，要求其重新生成符合規範的 JSON 結果。此過程採用迭代方式進行，最多執行 5 次修正循環；當生成結果同時通過解析驗證與結構檢查時，即停止迭代並輸出最終結果。若於最大迭代次數內仍未生成符合條件的結果，則保留最後一次生成結果，作為後續處理流程的輸入。

例如，「醬汁」節點的 Unit 屬性為空值，且 BOM 中出現 ID 為「醬料」的節點，該 ID 未存在於 Entities 節點中，Relations 亦包含 Target 為「佐料」的關聯，同樣未對應至任何 Entities 節點。系統驗證後產生下列錯誤訊息：

- BOM 節點 ID 「醬料」未存在於 Entities 節點中。
- Relations 中 Target 「佐料」未對應至任何 Entities 節點。
- Entities 節點「醬汁」的 Unit 為空值。

系統將上述錯誤訊息連同原始提示詞與輸入資料回饋至 LLM 進行修正，修正後的 BOM 節點 ID 更正為「醬汁」，Relations 中 Target 更正為「醬汁」，「醬汁」節點 Unit 補上「份」，通過驗證後輸出最終結果。

本研究所有比較方法，包括單一 LLM、單一 LLM 結合 BOM，以及本研究提出的多 LLM 結合 BOM 方法，皆採用相同的 JSON 生成與迭代修正機制，

以確保各方法在相同的生成條件下進行比較，避免因生成次數不同而影響實驗結果的公平性。各方法的差異主要在於後續是否導入 BOM 結構約束及多來源 LLM 整合機制，而非 JSON 生成階段的迭代流程。

綜上所述，本研究透過提示詞設計與生成策略，將非結構化自然語言資料轉換為結構化 JSON，並同時整合語意關係與組成結構。此流程不僅提供統一的資料表示方式，亦作為後續多來源資料整合與知識圖譜建構的基礎。

3.1.2 多來源 JSON 重組策略

在生成多個 JSON 結果後，本研究針對單一 JSON 進行結構重組與語意整理，以提升資料一致性與結構可用性，並作為後續多來源整合的基礎。本研究進一步引入關聯語意分類與結構對應機制，以提升語意與結構的一致性。整體流程如下：

1. 關聯語意分類

針對 JSON 中的關聯，本研究先對關聯詞進行語意分類，將其歸納為以下六種類型：

- (1) None（無明確語意）
- (2) General（一般語意關聯）
- (3) Base（類別階層關係）
- (4) Detail（組成細節關係）
- (5) Function（功能性關係）
- (6) Number（數量相關關係）

各類型關聯的對應處理方式如表 3.1 所示。

表 3.1、關聯分類對照表

類型	範例	處理方式
None	A → 有關 → B	保留，並於後續整合階段依相似度判斷是否補入
General	A → 是 → B	視語意是否重複決定保留或移除
Base	奶茶 → 屬於 → 飲料	保留，並於後續整合階段依相似度判斷是否補入
Detail	引擎 → 包含 → 活塞	檢查是否已存在於 BOM；若已存在則移除，否則保留於 Relations
Function	感測器 → 用於 → 偵測	保留，並於後續整合階段依相似度判斷是否補入
Number	螺絲 → 數量 → 4	視是否已於屬性或 BOM 表達決定移除

透過語意相似度計算，將關聯詞與各類型進行比對，當相似度高於 0.7 時，則歸類為對應類型。本研究的相似度閾值係依據方法設計需求進行設定。由於關聯詞

具有較高的語意表達彈性，若門檻過低，容易將不同語意關聯誤判為相同；反之，若門檻過高，則可能無法辨識語意相近但表達方式不同的關聯。因此，本研究採用 0.7 作為判定門檻，以兼顧語意辨識能力與資料整合效果。此步驟可將語意分散的關聯統一轉換為結構化語意類別。

例如，某來源 JSON 中「三杯雞 → 擁有 → 食材」的關聯詞「擁有」，經語意相似度比對後，與 Base 類型的相似度高於 0.7，歸類為 Base。

2. 結構對應與 BOM 關聯處理機制

針對分類結果為 Detail 的關聯，本研究進一步檢查其是否已存在於 BOM 結構中：

- (1) 若該關聯所對應的父子組成關係已存在於 BOM 結構中，則將 Relations 中重複的關聯移除，以避免結構重複表示。
- (2) 若該關聯未存在於 BOM 結構中，則保留於 Relations 中，作為額外的語意關聯資訊。

此機制可將隱含於語意關聯中的組成資訊轉換為顯式的層級結構，提升整體結構完整性。

例如，「主料 → 包含 → 雞腿肉/九層塔/薑片」屬 Detail 類型，且其父子組成關係已存在於 BOM 結構中，故將 Relations 中此類重複關聯移除。

3. 關聯轉屬性與簡化處理

針對非結構性關聯，本研究進行以下處理：

- (1) 關聯詞性為名詞者，轉換為對應實體的屬性，並移除原關聯。
- (2) 類型為 General 與 Number 的關聯，若其語意已由其他結構或屬性表達，則移除該關聯。

透過上述策略，可有效降低冗餘關聯，提升語意表示的集中性。

例如，若某來源 JSON 中存在「醬汁 → 比例 → 一比一比一」的關聯，其關聯詞「比例」為名詞性描述，經處理後轉換為「醬汁」實體的屬性 {"Name": "比例", "Value": "一比一比一"}，原關聯予以移除。

4. 實體與關聯篩選

為提升知識圖譜表示的清晰度，本研究進一步進行節點與關聯篩選：

- (1) 實體部分僅保留動詞以外的詞性（如名詞、專有名詞、代名詞等）。
- (2) 關聯部分僅保留具動詞語意的關係。
- (3) 移除名詞、形容詞、專有名詞、代名詞、數詞與量詞所構成的關聯。

此步驟可確保實體與關聯在語意角色上的一致性。

5. 屬性整合與去重複

針對實體的屬性，本研究進行去重複處理：

- (1) 若同一實體中存在語意相同或重複的屬性，則保留其中一項。
- (2) 移除冗餘屬性以提升資料精簡度與一致性。

透過上述重組策略，本研究可將原始 JSON 結果轉換為語意清晰且結構一致的資料表示。本研究不僅進行屬性整合，更透過關聯語意分類與結構對應機制，轉換為 BOM 層級結構，有效提升資料的語意一致性與結構完整性，並為後續多來源實體對齊與整合提供穩定基礎。綜上所述，本研究的 JSON 重組流程如圖 3.2 所示。




圖3.2、JSON 重組流程圖

3.1.3 多來源 JSON 集成與對齊

在完成單一 JSON 的重組與語意整理後，本研究進一步進行多來源 JSON 的實體對齊與資料整合，以提升整體資料一致性與完整性。本研究同時考量實體名稱與屬性語意進行相似度判斷，並設計關聯補全機制，以建立完整的語意結構。整體流程如下：

1. 基準 JSON 選擇

為確保整合過程具有一致性，本研究選擇一個 JSON 作為基準：

- (1) 依據 BOM 節點數量進行排序，節點數量最多者作為基準。
- (2) 若 BOM 節點數量相同，則依序比較實體數量與關聯數量；若仍相同，則依據 BOM 單位 (Unit) 的完整性進行判斷。
- (3) 基準 JSON 作為整合過程的主要參考來源，其實體結構與屬性內容優先保留，其他來源的資料則依對齊結果進行補充，以確保資料一致性與完整性。

例如，共四份來源 JSON。其中兩份的 BOM 節點數量並列最多，故依規則(2)進一步比較關聯數量：其中一份四筆關聯、另一份八筆關聯，關聯數較多者選為基準 JSON。

2. 實體對齊與屬性補全

在確定基準 JSON 後，本研究針對不同來源 JSON 與基準進行兩兩比對：

(1) 實體名稱相似度比對：

計算實體名稱的語意相似度，並採用較嚴格的 0.8 作為判定閾值。由於實體名稱為知識圖譜的核心識別資訊，若門檻過低，容易造成不同實體因名稱相近而被誤合併，因此採用較高判定門檻，以提升實體對齊準確性。當相似度高於 0.8 時，即判定為對應實體，並將缺漏實體補入基準 JSON。

例如，某來源 JSON 使用「三杯鸡」（簡體）而基準 JSON 使用「三杯雞」（繁體），經相似度比對後判定為同一實體，不重複建立節點。

(2) 屬性相似度比對：

將實體的每一個屬性以「名稱（Name）」與「值（Value）」分別轉換為語意向量，並透過 mean pooling 取平均，形成該屬性的語意表示。其後，針對不同來源實體的屬性進行兩兩比對，計算其語意向量相似度；當相似度高於 0.7 時，判定為語意相同的屬性，並進行補全與整合。由於屬性描述具有較高文字表達彈性，因此採用與關聯詞相同的判定門檻，以提升不同來源資料整合的完整性與一致性。

例如，基準 JSON 中「三杯雞」實體原無任何屬性，而另一來源 JSON 中同一實體包含屬性 {"Name": "分類", "Value": "台菜"}、{"Name": "部位", "Value": "雞肉"} 共兩筆。由於基準 JSON 中無對應屬性可比對，此兩筆屬性視為缺漏資訊，逕行補入基準 JSON 的「三杯雞」實體。




圖3.3、屬性語意向量建構與相似度計算示意圖

3. 關聯整合與補全機制

針對關聯的整合，本研究依據關聯語意分類進行處理：

(1) Base、None 與 Function 類型：

檢查基準 JSON 中是否已存在語意相近的關聯，並依前述相似度設定，以關聯名稱進行語意相似度比對（閾值 0.7）。若不存在，則新增該關聯至基準 JSON，並檢查其 Source 與 Target 是否存在於實體集合中；若不存在，則一併補入，以維持關聯與實體間的一致性。

例如，某來源 JSON 中存在「醬汁 → 製作 → 麻油」的 Function 類型關聯，而基準 JSON 中已有「醬汁 → 調製 → 麻油」之關聯。由於「製作」與「調製」之語意相似度達 0.7 以上，因此判定為相同語意關聯，不進行重複新增。

(2) General 類型：

檢查其 Source 與 Target 組合是否已存在於基準 JSON 的 General 類型關聯集合中；若該組合尚未出現，且其對應的實體已存在於基準 JSON 中，則補入。

該關聯至基準 JSON，以確保關聯完整性並避免重複。

4. 資料整合與一致性維持

整合過程以基準 JSON 為核心進行資料融合與一致性控制，主要包含資料整合策略與來源一致性檢查兩個部分。

(1) 資料整合策略

整體整合流程如下：

- 優先保留基準 JSON 的實體與屬性結構。
- 將其他來源 JSON 中缺漏的實體、屬性與關聯補入基準 JSON。
- 若不同來源間存在衝突資訊，則以基準 JSON 為優先，以維持整體結構一致性。

(2) 來源一致性與可追溯性檢查

為確保整合後知識圖譜的可信度，本研究進一步檢查所有新增或補入的實體、屬性與關聯是否可追溯至原始文本內容。若存在無法於原始語料中對應的資訊，則予以標記並排除，以避免非來源依據資訊被納入知識圖譜，並提升整體語意真實性與可靠性。

5. 結構維持

由於 BOM 結構已於前一階段完成重組與補全，本階段不對 BOM 結構進行修改。所有整合結果皆對應回既有 BOM 節點，以維持層級結構的正確性。

本研究以基準 JSON 為核心，結合實體名稱與屬性語意相似度進行實體對齊，並透過關聯補全機制整合多來源語意資訊。在維持既有 BOM 結構的情況下，有效提升資料的語意一致性與完整性，為後續知識圖譜建構提供穩定基礎。

3.2 錯誤類型分析

本研究針對 LLM 輔助生成的 JSON 結構，在知識圖譜建構過程中可能產生的錯誤進行系統性分類與定義。由於不同 LLM 在實體辨識、關係判定及結構表達上可能存在差異，其生成結果可能出現語意不一致、關係錯誤或結構衝突等問題，進而影響後續資料整合與知識圖譜品質。為有效分析與評估上述問題，本研究將錯誤類型分為實體層級、關係層級及結構層級三個面向，並進一步定義各類錯誤的判定標準，以作為後續結構統整與一致化方法的基礎。

3.2.1 實體抽取錯誤

在知識圖譜建構過程中，實體為構成圖譜的基本單位，其正確性將直接影響關係建立與整體結構品質。然而，在透過 LLM 由自然語言生成 JSON 結構的過程中，由於模型對語意理解及表達方式的差異，實體抽取結果可能出現多種錯誤情形。特別是在多個 LLM 同時生成資料的情境下，實體的命名方式、分類標準及抽取範圍可能不一致，進而影響後續資料整合與知識圖譜建構。

本研究將實體抽取錯誤歸納為以下幾種類型：

1. 實體命名不一致：

不同 JSON 結果中，對於相同概念可能使用不同名稱表示，如同一實體出現同義

詞、簡稱或不同語言表述等情形。此類問題會導致同一實體被視為不同節點，增加知識圖譜的冗餘與不一致性。

例如，某一 JSON 中使用「馬達」，而另一 JSON 使用「電動機」，兩者語意相同但名稱不同，若未進行對齊，將被視為兩個不同實體。

2. 實體重複：

在單一或多個 JSON 中，可能出現語意相同但被重複建立的實體節點。此類錯誤通常源於 LLM 對語句中不同描述的分割方式不一致，或多模型生成結果之間未經整合所致。

例如，同一 JSON 中同時存在「螺絲」與「螺絲（零件）」兩個節點，語意相同但被重複建立。

3. 實體邊界錯誤：

LLM 在抽取實體時，可能無法正確判斷實體範圍，如將多個概念合併為單一實體，或將一個完整實體拆分為多個節點，導致語意表達不完整或錯誤。

例如，「高溫馬達故障」被視為單一實體，而非拆分為「馬達」與「高溫故障」等相關概念。

4. 實體類型或分類錯誤：

實體所對應的分類可能出現不一致或錯誤標註的情形，例如將事件誤判為物件，或分類層級定義不一致，影響後續關係推論與結構分析。

例如，將「維修」標註為設備類型，而非事件或行為類型。

5. 屬性與實體混淆：

部分應作為屬性的資訊可能被錯誤抽取為實體，或反之，導致知識圖譜結構不清晰。

例如，「溫度：80°C」被建立為一個實體「80°C」，而非作為「溫度」的屬性值。

綜合而言，實體抽取錯誤主要源於語意表達差異與模型生成不一致性，且在多 LLM 生成情境下更為顯著。後續章節將透過實體正規化、相似度比對及屬性整合等方法，針對本研究關注的部分錯誤類型進行修正，以提升知識圖譜的整體一致性與準確性。

3.2.2 關係語意與方向錯誤

在知識圖譜中，關係用於描述實體之間的語意連結，其正確性將直接影響知識表示與後續推論結果。然而，在透過 LLM 由自然語言生成 JSON 結構的過程中，關係的語意表達與方向判斷可能受到語境理解差異的影響，導致關係定義不一致或錯誤。此類問題在多個 LLM 同時生成資料時更為顯著，進而影響多來源資料整合與知識圖譜建構的品質。

本研究將關係錯誤歸納為以下幾種類型：

1. 關係語意不一致：

不同 JSON 結果中，對於相同實體之間的關係，可能使用不同名稱表示相似語意，導致關係定義不統一，影響知識圖譜的一致性。

例如，JSON A 使用「包含」，而 JSON B 使用「組成」，兩者語意相近，但名稱不一致，將造成關係語意分散。

2. 關係方向錯誤：

關係的起點與終點可能被錯誤標示，導致語意方向顛倒，使知識圖譜中的語意關係產生誤解。

例如，正確關係應為感測器 → 屬於 → 機器，但模型生成機器 → 屬於 → 感測器。方向錯誤可能導致知識圖譜中路徑查詢或規則推理出現偏差。

3. 關係缺失：

部分應存在的關係未被 LLM 正確抽取，導致實體之間缺乏應有的語意連結，使知識圖譜出現資訊不完整的情形。

例如，文本中描述「馬達由轉子與定子組成」，但 JSON 中僅建立實體，未建立「組成」關係。

4. 關係冗餘：

在單一或整合後的知識圖譜中，可能同時存在多條語意相同或相近的關係，造成關係重複，影響結構簡潔性或語意表達清晰度。

例如，在整合多個 JSON 後，同時存在「馬達 包含 軸承」與「馬達 擁有 軸承」兩種語意相近的關係，形成重複的語意連結。

5. 關係語意模糊

部分關係名稱過於抽象或泛用，無法明確表達實體之間的實際語意關係，影響知識圖譜的可解釋性。

例如，使用「相關」或「有關」作為關係名稱，無法清楚表達實體之間的具體關聯。

綜合而言，關係錯誤主要源於語意理解差異與模型生成不一致性，且在多 LLM 生成情境下更為明顯。後續章節將透過關係映射與語意一致化方法，針對本研究所關注的部分關係錯誤進行修正，以提升知識圖譜的語意一致性與結構正確性。

3.2.3 結構與一致性錯誤

在知識圖譜建構過程中，除了實體與關係的正確性外，整體結構的合理性與一致性亦為影響圖譜品質的重要因素。特別是在多來源資料整合情境下，由於不同 LLM 生成的 JSON 結構在層級表達與關係連結上可能存在差異，容易導致知識圖譜出現結構不一致或不完整的情形。此外，若缺乏明確的結構約束機制，亦可能產生不合理的拓撲關係，影響後續分析與推論結果。

本研究將結構與一致性錯誤歸納為以下幾種類型：

1. 層級結構不一致：

不同 JSON 結果中，對於同一組實體之間的層級關係可能存在差異，導致整體結構無法對齊。此類問題通常表現為層級深度或表示方式不同，但不一定存在直接衝突。

例如，某一 JSON 中將「軸承」視為「馬達」的子組件，而另一 JSON 則將其直接連接至更高層級的產品，造成層級不一致。

2. 結構缺失：

部分應存在的層級或組成關係未被正確建立，使知識圖譜缺乏完整的結構資訊。

例如，文本中描述產品由多個組件組成，但在 JSON 或知識圖譜中僅存在實體節

點，未建立對應的組成層級關係。

3. 結構衝突：

在多來源資料整合過程中，不同 JSON 所定義的結構關係可能彼此衝突，導致同一實體同時具有不一致的父子關係。此類問題與層級結構不一致不同，前者涉及父子關係的直接矛盾，無法在未進行決策或規則定義的情況下同時成立。

例如，「齒輪」在某一 JSON 中屬於「變速箱」，但在另一 JSON 中則被歸類於不同的上層組件，造成結構衝突。

4. 循環關係：

在知識圖譜中出現不合理的循環結構，使層級關係失去意義，影響圖譜的邏輯正確性。

例如，若存在「A 包含 B」、「B 包含 C」，但同時出現「C 包含 A」，將形成循環關係。

5. 結構與實體不對應：

BOM 結構中的節點未能與知識圖譜中的實體正確對應，導致結構與語意表示之間產生不一致。

例如，BOM 中存在某一組件節點，但在實體集合中缺乏對應節點，或其 ID 不一致，造成結構斷裂。

綜合而言，結構與一致性錯誤主要源於多來源資料之間的結構差異與整合過程中的對齊問題。相較於僅依賴三元組關係的知識圖譜，BOM 所提供的層級與組成資訊可作為結構參考依據，有助於檢測與修正上述結構問題。後續章節將透過結構驗證與一致性檢核機制，針對本研究所關注的部分結構錯誤進行處理，以提升知識圖譜的結構完整性與一致性。

3.3 結構統整與一致化方法

為解決前述知識圖譜建構過程中所產生的實體、關聯及結構錯誤問題，本研究提出一套結構統整與一致化方法，針對多個 LLM 生成的 JSON 結果進行系統化整合與一致化處理。本方法依據錯誤類型進行對應設計，包含實體正規化、關係語意一致化及結構驗證等步驟，並進一步定義各步驟的判斷規則與處理機制，使整體流程具備可重現性與方法化特性，而非僅為資料處理流程描述。透過上述方法，可有效提升多來源資料整合後的語意一致性與結構完整性，並為後續知識圖譜建構提供穩定且一致的資料基礎。

3.3.1 實體正規化與去重複

在多個 LLM 生成的 JSON 結果中，實體的命名方式、抽取粒度及表示形式可能存在差異，容易導致實體重複、命名不一致及屬性混淆等問題。為提升知識圖譜的語意一致性與結構清晰度，本研究針對實體資料進行正規化與去重複處理，透過實體篩選、屬性轉換與相似度比對等步驟，統整多來源 JSON 中的實體資訊，並定義相應的判斷規則以確保處理結果的一致性與可重現性。

本研究的實體正規化與去重複流程如下：

1. 實體篩選機制：

針對每個 JSON 結果中的實體節點，依據詞性資訊進行篩選，僅保留名詞、專有

名詞與代名詞作為知識圖譜中的主要實體。例如，在描述「紅色汽車」時，「汽車」屬於名詞，因此保留為知識圖譜實體；而「紅色」屬於描述性形容詞，主要用於表達汽車的外觀特徵，不適合作為獨立節點，因此不保留為實體，以避免產生過多無意義或粒度過細的節點。

2. 屬性轉換：

對於未被保留為實體的描述性資訊，統一轉換為對應實體的屬性，並以鍵值對形式進行儲存。例如，在「紅色汽車」的描述中，「紅色」不建立為獨立實體，而是轉換為「汽車」實體的顏色屬性（顏色：紅色）。透過此方式，可將原本分散於多個節點中的描述資訊整合至對應實體中，提升語意表達的集中性，並降低實體與屬性混淆的情形。

3. 實體內屬性整合：

針對同一實體中可能存在的重複或語意相近屬性，本研究透過語意相似度判斷進行合併處理，以提升資料一致性。例如，同一汽車實體中可能同時存在「顏色」、「車身顏色」與「外觀顏色」等屬性，雖然名稱不同，但皆代表汽車的顏色資訊，因此將其整合為單一標準化屬性（如顏色：紅色）。此步驟可減少重複資訊，降低知識圖譜中的冗餘結構，並提升後續資料整合與查詢效率。

透過上述處理流程，可將多來源 JSON 中結構不一致的實體資訊轉換為語意較為一致且結構精簡的表示形式。此方法不僅可降低實體重複與命名差異所帶來的影響，亦可提升後續關係整合與結構驗證的效率，為知識圖譜建構提供穩定且一致的資料基礎。

3.3.2 關係處理與語意一致化

本節在前述實體正規化結果的基礎上，進一步針對關係進行處理。在多個 LLM 生成的 JSON 結果中，實體之間的關係可能因表達方式差異而產生語意不一致或冗餘的情形，進而影響知識圖譜的語意清晰度。因此，本研究針對關係資料進行篩選與簡化處理，以提升關係表示的一致性與結構合理性。

本研究的關係映射與語意一致化方法如下：

1. 關係節點篩選：

僅保留具動詞語意的關聯，作為實體之間的主要語意連結，以確保關聯能表達明確之語意關係。例如，在「引擎 → 安裝 → 車身」、「汽車 → 擁有 → 引擎」等關係中，「安裝」與「擁有」皆具有明確的動作或語意連結，因此保留作為知識圖譜中的關係；而如「紅色 → 屬於 → 汽車」等由描述性詞彙所形成的關係，因其本質上屬於屬性描述，並非實體間的語意互動，因此不保留，以降低非關鍵語意關係對整體圖譜結構的干擾。

2. 關係轉屬性機制：

當關係所連結的節點在實體正規化過程中被轉換為屬性時，原有關係將失去語意基礎，因此需同步移除。例如，原始知識圖譜中可能產生「汽車 → 具有顏色 → 紅色」的關係，但由於「紅色」屬於汽車的描述性資訊，經正規化後將轉換為汽車實體的屬性（顏色：紅色），不再作為獨立節點存在。因此，原有「具有顏色」關係將一併移除，避免產生指向不存在節點的無效關係，並維持知識圖譜結構的一致性。

3. 關係簡化與一致性維持：

透過上述篩選與轉換機制，將多來源 JSON 中表達冗餘或語意不明確的關係進行簡化處理。例如，不同 LLM 可能分別產生「引擎 → 安裝 → 車身」與「引擎 → 裝配 → 車身」兩種表示方式，若關係名稱未達語意一致判定標準，則保留其差異；反之，若經判定為相同語意，則進行合併，以避免重複關係造成圖譜冗餘。本方法未額外建立複雜的語意對齊模型，而是透過關係篩選、屬性轉換及結構約束機制，間接降低多來源生成結果的語意不一致問題，提升知識圖譜建構的一致性。

透過上述方法，可有效減少由多模型生成所帶來的關係冗餘與語意分散問題，使知識圖譜中的關係結構更加精簡且具一致性，為後續結構整合與查詢分析提供穩定基礎。

3.3.3 結構驗證與一致性檢核

在多來源 JSON 資料整合過程中，僅透過實體與關係的正規化仍不足以確保知識圖譜的整體正確性。由於不同 LLM 在生成結構化資料時，可能對層級關係與組成結構有不同理解，容易產生層級不一致、結構缺失或結構衝突等問題。因此，本研究引入 BOM 作為結構約束機制，對知識圖譜進行結構驗證與一致性檢核，以確保圖譜的結構合理性與層級完整性。

本研究的結構驗證與一致性檢核方法如下：

1. BOM 作為結構基準：

BOM 具備明確的父子關係與階層結構，可作為知識圖譜中組成關係的參考依據。在本研究中，BOM 結構於資料整合過程中保持不變，並用以比對知識圖譜中實體之間的層級關係，確保整體結構符合原始組成邏輯。

2. 層級關係檢核：

針對知識圖譜中的組成關係（如「包含」、「組成於」），檢查其是否符合 BOM 所定義的父子關係。若發現層級位置不一致，則標記為結構異常，並於後續整合過程中進行調整或修正。

3. 結構衝突檢測：

在多來源資料整合後，若同一實體在不同結構中對應至不同上層實體，則視為結構衝突。針對此類情形，本研究以 BOM 結構為優先判斷依據，優先保留符合 BOM 層級關係的結構；若無法直接對應至 BOM，則保留結構資訊並標記為待判定節點，以避免錯誤合併。

4. 結構合理性檢查：

檢查知識圖譜中是否存在不合理的層級關係（如循環結構或層級錯置），若發現異常，則進行標記與調整，以維持整體結構的合理性。

5. 實體與 BOM 對應驗證：

檢查 BOM 結構中的節點是否能對應至知識圖譜中的實體，若存在不一致情形，則進行補全或修正。

透過上述結構驗證與一致性檢核機制，本研究可有效識別並控制多來源資料整合過程中所產生的結構錯誤。相較於僅依賴三元組關係的知識圖譜方法，結合 BOM 可提供額外的層級與組成資訊，使知識圖譜在建構過程中具備結構約束能力。換言之，BOM 不僅作

為資料表示形式，更作為結構決策依據，用於輔助知識圖譜建構過程中的錯誤檢測、衝突處理與一致性維護，進而提升知識圖譜在結構一致性、語意正確性與實務應用上的可靠性。

3.4 知識圖譜建構與評估準則

在完成多來源 JSON 的重組、集成與一致化處理後，本研究進一步將整理後的結構化資料轉換為知識圖譜表示，並進行品質評估，以驗證所提出方法在語意一致性與結構完整性上的成效。本節首先說明知識圖譜的建構流程，其次介紹資料表示方式，最後針對建構結果進行品質評估。

本研究的知識圖譜以結構化表示為主，未涉及圖資料庫建置，而著重於語意與結構品質分析，並以此作為後續方法比較與評估的基礎。

3.4.1 知識圖譜建構流程

本研究以 LLM 生成的 JSON 與 BOM 結構為基礎建構知識圖譜。首先，透過 LLM 將自然語言資料轉換為包含實體、關聯與 BOM 層級資訊的 JSON 結構；接著，經由多來源 JSON 重組與整合方法，完成實體對齊、關聯一致化與屬性整合，並維持 BOM 層級的結構正確性。完成整合後，將實體與關聯轉換為知識圖譜的語意關係表示，並結合 BOM 所描述的父子層級關係，使知識圖譜同時具備語意關聯與結構資訊，形成可用於分析與比較的統一表示架構。

3.4.2 資料表示方式

為統一不同方法的輸出結果，本研究採用 JSON 作為主要知識表示形式，並以實體、關聯及 BOM 層級結構描述知識圖譜內容。其中，實體用以表示知識圖譜中的概念單位，關聯用以描述節點之間的語意連結，而 BOM 則用以表達實體之間的組成與層級關係。透過上述表示方式，可將單一 LLM、單一 LLM 結合 BOM，以及本研究提出的多 LLM 結合 BOM 方法的輸出結果，轉換為一致的結構化格式，使不同方法在語意資訊與結構資訊上具備統一的比較基礎，作為後續品質評估與結果分析的依據。

3.4.3 人工驗證與評估準則

為評估不同方法於知識圖譜建構的表現，本研究採用相對評估方式進行分析。評估基準以多來源 LLM 整合方法的輸出結果作為參考，並經人工檢視確認其符合原始文本語意與 BOM 結構邏輯後，作為後續比較依據。其餘方法的輸出結果則與該基準進行比較，以分析不同方法於知識圖譜建構品質上的差異。

本研究的評估主要分為語意層級與結構層級兩個面向。語意層級主要檢視實體與關聯的正確性與一致性；結構層級則著重於 BOM 父子關係與整體層級結構的合理性。

具體評估指標如下：

1. 實體一致性：檢視是否存在命名不一致、語意重複或重複實體的情形。
2. 關係一致性：分析不同來源間關係語意是否一致，並檢測是否存在冗餘關係。
3. 結構正確性：檢查 BOM 層級關係是否符合原始結構定義。

4. 結構完整性：確認實體與關係是否存在遺漏情形。
5. 異常結構檢測：檢視是否存在不合理或違反語意的關係組合。

除了上述人工檢視指標，本研究亦將評估結果公式化為學術界常用的精準度 (Precision)、召回率 (Recall) 與 F1-score，以提升分析的嚴謹性：

- Precision：模型輸出中正確項目的比例

$$Precision = \frac{\text{正確抽取的項目數}}{\text{模型抽取的總項目數}} \quad (1)$$

- Recall：基準集中正確項目被模型成功抽取的比例

$$Recall = \frac{\text{正確抽取的項目數}}{\text{基準集中的總項目數}} \quad (2)$$

- F1-score：Precision 與 Recall 的調和平均

$$F1 - score = \frac{2 \cdot Precision \cdot Recall}{Precision + Recall} \quad (3)$$

在本研究中，基準集由人工標記的正確實體、關係與 BOM 結構所構成，並以此作為比較依據。為了提升評估的嚴謹性，本研究不僅統計一致筆數，亦將其轉換為 Precision、Recall 與 F1-score 等常用指標，以人工標記基準集作為分母，確保不同方法的表現能以標準化方式進行比較。透過上述人工檢視與公式化指標，能更精確地分析各方法在語意一致性與結構完整性上的差異，並驗證所提出方法於多來源資料整合與知識圖譜建構上的有效性。

第四章 實驗結果與分析

4.1 資料集與實驗設計

本研究的實驗資料包含兩部分：短文本與長文本。短文本資料為透過 LLM 生成的自然語言句子，共計 100 筆，每筆內容均控制在 100 字以內。為提升資料多樣性與測試方法的泛化能力，資料內容涵蓋六種類型的語意情境，包括：食譜類（1–15）、電子產品類（16–30）、機械車輛類（31–45）、建築類（46–60）、生物結構類（61–75）及組織架構類（76–100）。各類型資料皆包含不同程度的實體關係與層級結構，用以模擬多來源資料的特性。此外，為進一步評估方法於較複雜語意情境下的表現，本研究另生成 50 筆長文本資料（約 150 至 600 字），同樣由 LLM 生成。相較於短文本，長文本包含較多實體關係與較複雜的層級結構，用以模擬資訊量較高的情境，並分析各方法在長文本條件下的穩定性與表現差異。

在實驗設計上，本研究比較三種方法的表現：（1）單一 LLM、（2）單一 LLM 結合 BOM 結構，以及（3）本研究提出的多 LLM 結合 BOM 方法。為確保比較公平性，三種方法皆採用相同的大型語言模型、JSON 驗證流程及最多五次的錯誤回饋迭代機制，差異主要在於提示詞是否加入 BOM 結構約束，以及是否進行多 LLM 結果整合。實驗選用兩種大型語言模型，分別為 XI-Mimo-V2.5Pro 與 Deepseek-v4-pro。為增加生成結果的多樣性並模擬多來源資料情境，每個模型皆進行兩次獨立生成，以降低單次生成隨機性對結果造成的影響，因此每個模型共產生兩組結構化 JSON 結果，兩種模型合計形成四組 JSON 輸出。單一 LLM 方法採用本研究設計的提示詞架構進行知識圖譜生成，但移除其中 BOM 結構約束相關內容；單一 LLM 結合 BOM 方法則保留 BOM 結構約束，使模型於生成過程中考量材料清單的階層與組成關係；而本研究提出的多 LLM 結合 BOM 方法則同時整合兩種模型共四組 JSON 結果，透過多來源資料整合、一致化處理及 BOM 結構約束機制產生最終知識圖譜。於單一 LLM 與單一 LLM 結合 BOM 方法中，各模型所生成的兩組結果皆分別進行評估，以分析不同模型在未導入與導入 BOM 結構約束後的表現差異。所有方法的輸出皆轉換為統一的 JSON 結構，以確保後續分析具有一致的比較基準。藉由不同模型與多次獨立生成所形成的多來源輸出，本研究得以模擬實際多來源知識整合情境，並進一步驗證所提出方法於語意一致性、結構完整性與知識圖譜建構品質上的表現。三種方法之實驗設定比較如表 4.1 所示。

表 4.1、三種知識圖譜建構方法之實驗設定比較

方法	模型	生成次數	Prompt 設定	BOM 約束	多 LLM 整合
單一 LLM	XI-Mimo-V2.5Pro、Deepseek-v4-pro	每模型獨立生成 2 次	本研究提示詞架構（移除 BOM 約束）	×	×
單一 LLM + BOM	XI-Mimo-V2.5Pro、Deepseek-v4-pro	每模型獨立生成 2 次	本研究提示詞架構（包含 BOM 約束）	✓	×
多 LLM + BOM（本研究）	XI-Mimo-V2.5Pro、Deepseek-v4-pro	每模型獨立生成 2 次	本研究提示詞架構（包含 BOM 約束）	✓	✓

4.2 評估方法與判定準則

本研究的評估流程係依據第三章 3.4.3 所建立的評估架構進行實作，並據以設計具體的比較流程，以分析不同方法於知識圖譜建構任務中的表現差異。為確保不同方法的輸出具備一致性，所有結果皆先轉換為統一的 JSON 表示格式，以作為後續比較分析的基礎。在評估基準的建立上，本研究以所提出的多來源整合知識圖譜建構方法所產生的結果作為參考基準，並經人工檢視確認其符合原始文本語意與 BOM 結構邏輯後，作為後續比較分析的依據。其餘方法的輸出結果則與該基準進行逐項比對。

在評估流程上，針對每一筆資料，依序比對其實體、關聯與結構資訊與基準結果的差異，並依據第三章所定義的評估原則判定其正確性。對於未包含 BOM 結構的方法，則將其關聯結果對應至基準的 BOM 層級結構，以檢查其是否符合合理的父子關係。在結果判定上，本研究以「一致結果」作為主要比較指標，首先檢查方法輸出結果是否與基準結果完全一致；若存在表達形式差異，則進一步由評估者判斷其是否於語意上等價，例如關係方向對等、命名同義替換或結構表達差異等情形。若語意與結構意義相符，仍判定為一致；反之，若存在實體遺漏、關聯錯誤或結構不合理等情形，則判定為不一致。

最後，本研究分別統計短文本與長文本資料中各方法的一致筆數，並同時計算 Precision、Recall 與 F1-score，以分析不同方法於不同文本類型下的知識圖譜建構表現差異，並作為整體方法有效性的比較依據。

4.3 實驗結果分析

為評估本研究方法的有效性，本節針對不同方法在有無 BOM 結構輔助下的表現進行比較分析，並分別於短文本與長文本情境中進行實驗。比較方法包含單一 LLM、單一 LLM 結合 BOM，以及本研究提出的多 LLM 結合 BOM 方法。

4.3.1 短文本結果分析

在短文本（共 100 筆）情境下，單一 LLM 於未使用 BOM 結構時，其結果一致筆數約為 72 至 77 筆；加入 BOM 結構後，提升至約 81 至 86 筆，顯示 BOM 所提供的層級與組成資訊能協助改善結構判定，進而提升整體結果的正確性。短文本實驗結果如圖 4.1 所示。




圖4.1、短文本結果比較（共 100 筆）

進一步以公式化指標檢視，如表 4.2 所示，其他模型平均 Precision、Recall 與 F1-score 約為 0.79，而本研究提出的多 LLM 結合 BOM 方法三項指標皆達到 1.00，顯示結果完全一致。

表 4.2、短文本方法比較之 Precision、Recall 與 F1-score

方法	Precision	Recall	F1-score
其他模型平均	0.79	0.79	0.79
多 LLM + BOM (本研究)	1.00	1.00	1.00

由結果可觀察到，BOM 對於結構層級關係具有顯著輔助效果，使模型在處理具有明確組成關係的文本時，能降低層級判斷錯誤與結構不一致的情形。然而，僅靠 BOM 仍不足以達到完全一致。本研究所提出的多來源整合方法在結合 BOM 結構後，可達 100 筆一致結果，並在 Precision、Recall 與 F1-score 上皆達到 1.00，顯示多來源生成機制能有效補足單一模型在實體與關聯抽取上的不足，且 BOM 結構進一步提供層級約束，使整體結果趨於一致與完整。

4.3.2 長文本結果分析

在長文本（共 50 筆）情境下，單一 LLM 的結果一致筆數顯著下降，未使用 BOM 結

構時僅為 0 至 2 筆；即使加入 BOM 結構，仍僅為 0 至 2 筆，顯示在語意與結構較為複雜的情境下，單一模型難以穩定維持完整的語意抽取與結構建構能力。此現象主要源於長文本的上下文限制與語法複雜度：模型在一次生成中難以同時兼顧實體、關係與 BOM 層級的完整度，並且容易因資訊分散而產生遺漏或幻覺。尤其在並列句型與跨段落描述較多的情境下，模型更容易失去語意連貫性，導致結構不完整或錯誤。長文本的實驗結果如圖 4.2 所示。




圖4.2、長文本結果比較（共 50 筆）

進一步以公式化指標檢視，如表 4.3 所示，其他模型平均 Precision、Recall 與 F1-score 僅約為 0.02，顯示在長文本情境下幾乎無法維持正確抽取。而本研究提出的多 LLM 結合 BOM 方法則可達 46 筆一致結果，Precision 與 Recall 分別為 0.92 與 1.00，F1-score 為 0.96，顯示在複雜語境下仍能維持高度穩定性與完整性。

表 4.3、長文本方法比較之 Precision、Recall 與 F1-score

方法	Precision	Recall	F1-score
其他模型平均	0.02	0.02	0.02
多 LLM + BOM (本研究)	0.92	1.00	0.96

相較之下，本研究所提出的多來源整合方法透過多模型生成結果的互補性，可有效降低單一模型於長文本情境下的不穩定性。此外，BOM 結構亦在此過程中提供層級約束，

能修正不同模型間的結構差異，使整體輸出維持較佳的層級一致性。此結果凸顯多來源整合與結構約束在長文本情境下的必要性與優勢，並進一步說明單一模型在處理複雜語境時的侷限性。

4.3.3 整體比較分析

綜合短文本與長文本的結果可觀察到，BOM 結構透過引入明確的層級與組成關係，能有效提升知識圖譜在結構層面的正確性，尤其在短文本情境中效果顯著；然而在長文本中，僅靠 BOM 仍不足以維持完整性。本研究提出的多來源 LLM 整合方法，透過不同模型輸出的互補性，搭配 BOM 的層級約束，能顯著提升抽取的穩定性與一致性，並降低單一模型因生成不穩定所造成的偏差。整體而言，BOM 結構提供必要的層級約束，而多來源整合則補足單一模型的不足，兩者結合使知識圖譜建構在不同文本情境下皆能維持高度正確性與完整性，凸顯本研究方法的必要性與優勢。

4.4 錯誤分析與案例討論

為進一步分析不同方法於知識圖譜建構過程中的表現差異，本節根據實驗結果，系統性歸納三類主要錯誤類型，包括：實體層級錯誤、關聯層級錯誤以及結構層級錯誤。

案例一：食材組成描述之錯誤分析

原始輸入文本如下：

「豬肉內餡使用豬後腿肉、豬皮凍、薑末和醬油調製。」

在此案例中，單一 LLM 在實體與關聯層級皆出現明顯錯誤。

在實體層級方面，模型僅辨識出「豬後腿肉」，未能抽取「豬皮凍」、「薑末」與「醬油」等關鍵材料，此屬於典型的實體遺漏錯誤。此現象顯示單一 LLM 在處理列舉型文本時，傾向於抽取顯著或高頻實體，而忽略並列結構中的其他組成元素，導致實體資訊不完整。

在關聯層級方面，模型未能辨識「調製」此一關鍵動詞所隱含的功能性關聯，使「豬肉內餡」與各材料之間缺乏語意連結，此屬於關聯語意缺失錯誤。該問題反映出單一 LLM 在將自然語言動詞轉換為結構化關聯時仍存在不足，特別是在功能性或製程語意的表達上。

單一 LLM 輸出結果如下：

實體：豬肉內餡、豬後腿肉

由結果可知，僅能辨識部分實體，且未形成任何結構或關聯表示，導致語意與結構皆不完整。

相較之下，本研究方法結果如下：

實體：豬肉內餡、豬後腿肉、豬皮凍、薑末、醬油




圖4.3、案例一：本研究方法 BOM 層級結構圖

關聯：

豬肉內餡 → 調製 → 豬後腿肉/豬皮凍/薑末/醬油

本研究方法透過整合多個 LLM 輸出結果的互補性，將不同模型所抽取的實體進行集成，有效補足單一模型所遺漏的資訊。此外，透過關聯語意分類機制，將文本中的動詞（如「調製」）轉換為具語意的結構化關聯，使原本隱含於自然語言中的製程語意得以完整表達，顯著提升知識圖譜的語意完整性。

案例二：設備組成與運作語意之錯誤分析

原始輸入文本如下：

「均質機由高壓泵、均質閥和壓力表構成，將牛奶中的脂肪球打碎成均勻的微小顆粒，防止乳脂分離。」

在此案例中，單一 LLM 雖能正確辨識設備組成，但在運作語意建構上仍存在明顯缺陷。

在實體層級方面，模型未能抽取「脂肪球」、「微小顆粒」及「乳脂分離」等與製程相關的關鍵實體，此屬於實體遺漏錯誤。此結果顯示，單一 LLM 較偏向抽取靜態結構性實體（如設備組件），而對於動態過程中涉及的狀態或轉換實體辨識能力不足。

在關聯層級方面，模型未能辨識「打碎」與「防止」等描述製程機制的關鍵動詞，導致設備運作過程中的因果與功能關係未被建構，此屬於關聯語意缺失錯誤。

單一 LLM 結合 BOM 結構結果如下：

實體：均質機、高壓泵、均質閥、壓力表




圖4.4、案例二：單一 LLM 結合 BOM 層級結構圖

本研究方法結果如下：

實體：均質機、高壓泵、均質閥、壓力表、脂肪球、微小顆粒、乳脂分離




圖4.5、案例二：本研究方法 BOM 層級結構圖

關聯：

均質機 → 打碎 → 脂肪球

脂肪球 → 打碎 → 微小顆粒

均質機 → 防止 → 乳脂分離

相較之下，本研究方法不僅保留由 BOM 所提供的設備組成階層結構，確保「組成關係」的正確性，同時進一步建構「運作關係」，將製程中的動態語意轉換為結構化關聯。此外，BOM 結構作為結構約束機制，有效區分「組成關係」與「功能關係」，使知識圖譜在結構與語意層面皆具備良好一致性與可解釋性。

綜合上述案例可觀察到，單一 LLM 在知識圖譜建構過程中，其錯誤主要集中於實體遺漏與關聯語意缺失，且在複雜語意情境下更為明顯。本研究方法透過多來源輸出整合與 BOM 結構約束，不僅有效降低實體遺漏問題，亦能將自然語言中的隱含語意轉換為明確的結構化關聯，進而提升知識圖譜的語意完整性與結構一致性。

第五章 結論與未來展望

5.1 研究結果

本研究針對知識圖譜建構過程中，單一 LLM 在實體抽取、關聯建構及結構表示上的不穩定性與不完整性問題，提出一套結合多來源 LLM 輸出整合與 BOM 結構約束的方法，以提升知識圖譜在語意一致性與結構完整性上的品質。在方法上，本研究首先透過多個 LLM 生成結構化 JSON 資料，並設計結構統整與一致化流程，包含實體正規化、關係處理與結構驗證等機制，以整合不同來源的資訊並降低語意與結構上的不一致問題。此外，本研究亦引入 BOM 作為結構約束基準，使知識圖譜在建構過程中能維持明確的層級關係與組成邏輯。

在實驗結果方面，透過短文本與長文本資料的比較分析可知，單一 LLM 在未使用結構輔助時，容易出現實體遺漏與關聯語意缺失等問題；即使結合 BOM，雖可改善結構正確性，但在語意完整性上仍存在限制。相較之下，本研究所提出的多來源整合方法，能透過不同模型輸出的互補性，有效提升實體與關聯的完整性，並在 BOM 結構約束下進一步提升整體結構一致性。特別是在長文本情境中，單一模型的表現明顯下降，而本研究方法仍能維持較高的一致性結果，顯示所提出方法在處理複雜語意結構時具備較佳的穩定性與穩健性。

綜合而言，本研究證實透過多來源 LLM 輸出整合與 BOM 結構約束的結合，可有效改善知識圖譜建構過程中的語意不完整與結構不一致問題，並提升整體知識表示的品質與一致性。

5.2 實務應用展望

本研究所提出的方法，在多個具有層級結構與複雜關聯的實務領域中具備應用潛力，以下分別說明。

1. 智慧製造與產品結構管理

在製造業中，產品組成關係複雜且涉及大量文件與規格說明。本研究方法可將非結構化的產品說明文件、維修手冊或設計文件，透過多來源 LLM 自動轉換為結合 BOM 層級的知識圖譜，取代人工建立產品知識庫的高成本流程。工程師可透過知識圖譜快速查詢零件組成關係、替換元件或追溯故障來源，有效提升維修與設計決策的效率。

2. 供應鏈管理與風險分析

供應鏈涉及多層級的供應商、物料與產品組成關係，與 BOM 結構高度契合。本研究方法可整合來自不同來源的供應商資料、採購文件與物料清單，建構具層級一致性的供應鏈知識圖譜，進而支援斷料風險分析、替代供應商推薦及跨層級影響評估等應用，協助企業在面對供應鏈中斷時快速做出應對決策。

3. 技術文件與知識庫自動建構

企業內部累積大量非結構化的技術文件、標準規範與操作程序，人工整理耗時且難以維護。本研究方法可自動將這些文件轉換為結構化知識圖譜，並透過 BOM 層級

約束確保知識的組成邏輯一致，適用於建立企業內部知識庫、標準作業程序管理系統，或支援後續的智慧問答與知識檢索應用。

4. 醫療與生物醫學領域

在醫療領域中，疾病、症狀、藥物與治療方案之間存在複雜的層級與關聯關係，與本研究所處理的 BOM 組成結構具有結構上的相似性。本研究方法可應用於整合多來源醫學文獻或電子病歷，建構具層級一致性的醫療知識圖譜，支援臨床決策輔助、藥物交互作用分析及罕見疾病知識整合等應用。

5. Graph-RAG 檢索增強生成

將本研究所建構的知識圖譜作為 Graph-RAG（圖形化檢索增強生成）的知識來源，可透過 BOM 層級路徑進行結構化檢索過濾，有效降低檢索噪音並提升生成內容的事實性與可追溯性。相較於一般非結構化向量檢索，結合 BOM 層級的知識圖譜能提供更具邏輯脈絡的上下文，對需要精確知識推論的問答系統或報告生成系統特別有利。實務部署時，可將使用者查詢上下文作為檢索過濾條件以提升相關性，但需同時注意資料隱私、來源可追溯性與人工審核機制，確保知識庫品質與系統可靠性。

5.3 研究限制

儘管本研究在方法設計與實驗結果上取得一定成效，仍存在若干限制有待後續研究進一步探討。首先，在資料規模方面，本研究實驗資料以 LLM 自動生成的短文本與長文本為主，資料來源較為單一，尚未涵蓋真實企業環境中的多樣化文件類型。因此，未來研究可進一步引入更大規模且來源多元的真實資料集，以驗證本研究方法於不同領域與資料特性下的泛化能力。此外，在評估方式方面，本研究以多來源整合結果經人工檢視後作為參考基準，雖可作為相對評估依據，但仍缺乏外部標準答案作為絕對參照。未來可考慮建立由領域專家標註的標準資料集，以提升評估結果的客觀性與可靠性。

其次，在模型選擇方面，本研究僅採用兩種大型語言模型進行多來源生成，模型組合的多樣性仍有限。由於不同模型在語意理解與結構生成上具有不同特性與偏差，因此未來可進一步納入更多模型組合，以分析不同模型特性對整合結果的影響。此外，本研究的 BOM 結構約束方法係建立於具有組成與層級關係的資料前提下，對於缺乏明確層級特性的文本（如事件描述或平行關係文本），其結構約束效果可能較為有限，此亦為本研究方法於適用範圍上的限制。

5.4 未來研究方向

基於上述研究結論與限制，本研究提出以下幾項未來研究方向，進一步提升方法的完整性與實務應用價值。

1. 擴展至真實領域資料集

未來研究可將本方法應用於真實製造業文件、醫療病歷或供應鏈資料等領域資料集，並與領域專家合作建立標準評估基準，以驗證方法在真實情境下的可靠性與實用性。

2. 引入更多 LLM 模型組合

現有方法以兩種 LLM 進行多來源生成，未來可系統性地比較不同模型組合（如

規模差異、訓練資料差異)對整合結果的影響,並探索最佳模型組合策略,以在效能與成本之間取得平衡。

3. 自動化評估機制

目前評估流程仍需仰賴人工檢視確認基準正確性,未來可設計自動化的知識圖譜品質評估機制,例如結合語意相似度模型與規則式驗證,以降低人工成本並提升評估效率與一致性。

4. 動態知識圖譜更新

本研究聚焦於靜態知識圖譜的建構,未來可進一步探討如何在資料持續更新的情境下,維持知識圖譜的結構一致性與語意準確性,例如設計增量式更新機制,以支援知識圖譜的長期維護與演進。

5. 圖譜推理與語意推論研究

未來研究可進一步結合圖譜推理與語意推論方法,提升知識圖譜對隱含關係與複雜語意的理解能力,並強化其於複雜查詢與知識推論任務中的應用效果。



參考文獻

- [1] Zhu, J., Wang, Y., Tong, W., Li, S., Wang, M., & Wang, C. (2025). Gold Deposit Ontology Guides Large Language Model to Transform Text into Knowledge Graphs for Gold Deposits. *Minerals*, 16(1), 50. <https://doi.org/10.3390/min16010050>
- [2] Tong, B., Zhou, Y., Zhang, C., Tang, J., Li, J., & Chen, L. (2025). GalaxyWeaver: Autonomous Table-to-Graph Conversion and Schema Optimization with Large Language Models. *Proceedings of the VLDB Endowment*, 18(12), 5100–5112. <https://doi.org/10.14778/3750601.3750630>
- [3] Lou, P., Yu, D., Jiang, X., Hu, J., Zeng, Y., & Fan, C. (2023). Knowledge Graph Construction Based on a Joint Model for Equipment Maintenance. *Mathematics*, 11(17), 3748. <https://doi.org/10.3390/math11173748>
- [4] Yang, R., Yang, B., Ouyang, S., She, T., Feng, A., Jiang, Y., Lecue, F., Lu, J., & Li, I. (2024, July 15). *Graphusion: Leveraging large language models for scientific knowledge graph fusion and construction in NLP education*. arXiv.org. <https://arxiv.org/abs/2407.10794>
- [5] Zhong, L., Wu, J., Li, Q., Peng, H., & Wu, X. (2023). A Comprehensive Survey on Automatic Knowledge Graph Construction. *ACM Computing Surveys*, 56(4), 1–62. <https://doi.org/10.1145/3618295>
- [6] Bermejo, V. J., Gago, A., Gálvez, R. H., & Harari, N. (2025). LLMs outperform outsourced human coders on complex textual analysis. *Scientific Reports*, 15(1), 40122. <https://doi.org/10.1038/s41598-025-23798-y>
- [7] Huang, L., Yu, W., Ma, W., Zhong, W., Feng, Z., Wang, H., Chen, Q., Peng, W., Feng, X., Qin, B., & Liu, T. (2024). A survey on hallucination in large language models: principles, taxonomy, challenges, and open questions. *ACM Transactions on Information Systems*, 43(2), 1–55. <https://doi.org/10.1145/3703155>
- [8] 陳鍾誠、廖先志 (2024)。AI 的回答可信嗎？淺談 LLM（大型語言模型）中的 AI 幻覺（hallucination）。最高檢察署月刊，(23)，9-12。
<https://www.airitilibrary.com/Article/Detail?DocID=P20240124001-N202408020009-00007>
- [9] Dagdelen, J., Dunn, A., Lee, S., Walker, N., Rosen, A. S., Ceder, G., Persson, K. A., & Jain, A. (2024). Structured information extraction from scientific text with large language models. *Nature Communications*, 15(1), 1418. <https://doi.org/10.1038/s41467-024-45563-x>
- [10] Jaradeh, M. Y., Singh, K., Stocker, M., Both, A., & Auer, S. (2023). Information extraction pipelines for knowledge graphs. *Knowledge and Information Systems*, 65(5), 1989–2016. <https://doi.org/10.1007/s10115-022-01826-x>
- [11] Liu, J., Ren, J., Zheng, W., Chi, L., Lee, I., & Xia, F. (2022). Web of Scholars: A Scholar Knowledge Graph. *arXiv (Cornell University)*. <https://doi.org/10.48550/arxiv.2202.11311>
- [12] Wang, X., He, X., Cao, Y., Liu, M., & Chua, T. (2019). KGAT: Knowledge Graph Attention Network for Recommendation. *arXiv (Cornell University)*. <https://doi.org/10.48550/arxiv.1905.07854>
- [13] Bao, J., Duan, N., Yan, Z., Zhou, M., & Zhao, T. (2016, December 1). *Constraint-Based Question Answering with Knowledge Graph*. ACL Anthology. <https://aclanthology.org/C16->

- [14] Suchanek, F. M., Kasneci, G., & Weikum, G. (2007). Yago: a core of semantic knowledge. *The Web Conference*, 697–706. <https://doi.org/10.1145/1242572.1242667>
- [15] Dehal, R. S., Sharma, M., & Rajabi, E. (2025). Knowledge Graphs and Their Reciprocal Relationship with Large Language Models. *Machine Learning and Knowledge Extraction*, 7(2), 38. <https://doi.org/10.3390/make7020038>
- [16] Han, P., Li, X., Wang, X., Wang, S., Gao, C., & Chen, W. (2022). Exploring the effects of drug, disease, and protein dependencies on biomedical named entity recognition: A comparative analysis. *Frontiers in Pharmacology*, 13, 1020759. <https://doi.org/10.3389/fphar.2022.1020759>
- [17] Nadeau, D., & Sekine, S. (2007). A survey of named entity recognition and classification. *Linguisticae Investigationes*, 30(1), 3–26. <https://doi.org/10.1075/li.30.1.03nad>
- [18] Bach, N., & Badaskar, S. (2007). A review of relation extraction. <https://nguyenbh.github.io/publication/bach-badaskar-2007/bach-badaskar-2007.pdf>
- [19] Yang, Y., Wu, Z., Yang, Y., Lian, S., Guo, F., & Wang, Z. (2022). A Survey of Information Extraction Based on Deep Learning. *Applied Sciences*, 12(19), 9691. <https://doi.org/10.3390/app12199691>
- [20] Huang, Z., Xu, W., & Yu, K. (2015, August 9). *Bidirectional LSTM-CRF models for sequence tagging*. arXiv.org. <https://arxiv.org/abs/1508.01991>
- [21] Devlin, J., Chang, M., Lee, K., & Toutanova, K. (2018, October 11). *BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding*. arXiv.org. <https://arxiv.org/abs/1810.04805v2>
- [22] Lample, G., Ballesteros, M., Subramanian, S., Kawakami, K., & Dyer, C. (2016). *Neural architectures for named entity recognition*. In H. M. Bunt & P. Koehn (Eds.), *Proceedings of the 2016 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies* (pp. 260–270). Association for Computational Linguistics. <https://aclanthology.org/N16-1030/>
- [23] Gao, T., Fisch, A., & Chen, D. (2020). Making pre-trained language models better few-shot learners. *arXiv (Cornell University)*. <https://doi.org/10.48550/arxiv.2012.15723>
- [24] Pan, J. Z., Razniewski, S., Kalo, J.-C., Singhanian, S., Chen, J., Dietze, S., Jabeen, H., Omeliyanenko, J., Zhang, W., Lissandrini, M., Biswas, R., de Melo, G., Bonifati, A., Vakaj, E., Dragoni, M., & Graux, D. (2023). *Large language models and knowledge graphs: Opportunities and challenges* (arXiv preprint). arXiv. <https://doi.org/10.48550/arXiv.2308.06374>
- [25] Cao, L., Sun, J., & Cross, A. (2024). An Automatic and End-to-End System for Rare Disease Knowledge Graph Construction based on Ontology-Enhanced Large Language Models: Development Study. *JMIR Medical Informatics*, 12, e60665. <https://doi.org/10.2196/60665>
- [26] Wei, J., Wang, X., Schuurmans, D., Bosma, M., Ichter, B., Xia, F., Chi, E., Le, Q. V., & Zhou, D. (2022). *Chain-of-thought prompting elicits reasoning in large language models*. arXiv. <https://arxiv.org/abs/2201.11903>

- [27] Xu, D., Chen, W., Peng, W., Zhang, C., Xu, T., Zhao, X., Wu, X., Zheng, Y., Wang, Y., & Chen, E. (2024). Large language models for generative information extraction: a survey. *Frontiers of Computer Science*, 18(6). <https://doi.org/10.1007/s11704-024-40555-y>
- [28] Ji, S., Pan, S., Cambria, E., Marttinen, P., & Yu, P. S. (2020). A survey on Knowledge Graphs: Representation, Acquisition and Applications. *arXiv (Cornell University)*. <https://doi.org/10.48550/arxiv.2002.00388>
- [29] Hogan, A., Blomqvist, E., Cochez, M., D'amato, C., De Melo, G., Gutierrez, C., Kirrane, S., Gayo, J. E. L., Navigli, R., Neumaier, S., Ngomo, A. N., Polleres, A., Rashid, S. M., Rula, A., Schmelzeisen, L., Sequeda, J., Staab, S., & Zimmermann, A. (2021). Knowledge Graphs. *ACM Computing Surveys*, 54(4), 1–37. <https://doi.org/10.1145/3447772>
- [30] Suchanek, F. M., Abiteboul, S., & Senellart, P. (2011). PARIS: Probabilistic alignment of Relations, instances, and schema. *arXiv (Cornell University)*. <https://doi.org/10.48550/arxiv.1111.7164>
- [31] Hofer, M., Obraczka, D., Saeedi, A., Köpcke, H., & Rahm, E. (2024). Construction of Knowledge graphs: current state and challenges. *Information*, 15(8), 509. <https://doi.org/10.3390/info15080509>
- [32] Paulheim, H. (2016). Knowledge graph refinement: A survey of approaches and evaluation methods. *Semantic Web*, 8(3), 489–508. <https://doi.org/10.3233/sw-160218>
- [33] Carlson, A., Betteridge, J., Kisiel, B., Settles, B., Hruschka, E., & Mitchell, T. (2010). Toward an architecture for Never-Ending Language Learning. *Proceedings of the AAAI Conference on Artificial Intelligence*, 24(1), 1306–1313. <https://doi.org/10.1609/aaai.v24i1.7519>
- [34] Etzioni, O., Banko, M., Soderland, S., & Weld, D. S. (2008). Open information extraction from the web. *Communications of the ACM*, 51(12), 68–74. <https://doi.org/10.1145/1409360.1409378>
- [35] Bian, H. (2025). LLM-empowered knowledge graph construction: A survey. *ArXiv.org*. <https://doi.org/10.48550/arxiv.2510.20345>
- [36] Jarnac, L., Chabot, Y., & Couceiro, M. (2024). Uncertainty Management in the Construction of Knowledge Graphs: a Survey. *arXiv (Cornell University)*. <https://doi.org/10.48550/arxiv.2405.16929>
- [37] Nananukul, N., Sisaengsuwanchai, K., & Kejriwal, M. (2024). Cost-Efficient prompt engineering for unsupervised entity resolution. *Research Square*. <https://doi.org/10.21203/rs.3.rs-4177791/v1>
- [38] Nentidis, A., Akasiadis, C., Charalambidis, A., & Artikis, A. (2025). Dealing with Inconsistency for Reasoning over Knowledge Graphs: A Survey. *ArXiv.org*. <https://doi.org/10.48550/arxiv.2502.19023>
- [39] Ryen, V., Soylu, A., & Roman, D. (2022). Building Semantic Knowledge Graphs from (Semi-)Structured Data: A Review. *Future Internet*, 14(5), 129. <https://doi.org/10.3390/fi14050129>
- [40] Razniewski, S., Arnaout, H., Ghosh, S., & Suchanek, F. (2023). Completeness, Recall, and Negation in Open-World Knowledge Bases: A survey. *arXiv (Cornell University)*. <https://doi.org/10.48550/arxiv.2305.05403>

- [41] Zhang, Q., Dong, J., Tan, Q., & Huang, X. (2023). Integrating entity attributes for Error-Aware knowledge graph embedding. *IEEE Transactions on Knowledge and Data Engineering*, 36(4), 1667–1682. <https://doi.org/10.1109/tkde.2023.3310149>
- [42] Zhai, S., Lu, X., Wang, C., Hong, Z., Shan, J., & Ma, Z. (2024). Correcting inconsistencies in knowledge graphs with correlated knowledge. *Big Data Research*, 36, 100450. <https://doi.org/10.1016/j.bdr.2024.100450>
- [43] Ghanem, H., & Cruz, C. (2025). Fine-tuning or prompting on LLMs: evaluating knowledge graph construction task. *Frontiers in Big Data*, 8, 1505877. <https://doi.org/10.3389/fdata.2025.1505877>
- [44] Cai, E., & O'Connor, B. (2025). Understanding the effect of knowledge graph extraction error on downstream graph analyses: a case study on affiliation graphs. *Applied Network Science*, 10(1). <https://doi.org/10.1007/s41109-025-00749-0>
- [45] Wu, C., Liu, X., Ding, K., Xin, B., Lu, J., Liu, J., & Huang, C. (2024). Cybersecurity entity recognition for blockchain of things via Hierarchical Attention Mechanism. *Research Square*. <https://doi.org/10.21203/rs.3.rs-3839229/v1>
- [46] Xu, X., Li, Z., Zhang, H., & Ma, K. (2025). Named entity recognition for Chinese electronic medical records by integrating knowledge graph and ClinicalBERT. *Frontiers in Artificial Intelligence*, 8, 1634774. <https://doi.org/10.3389/frai.2025.1634774>
- [47] Neumann, M., King, D., Beltagy, I., & Ammar, W. (2019). SCISPACY: Fast and Robust models for Biomedical natural language Processing. *arXiv (Cornell University)*. <https://doi.org/10.48550/arxiv.1902.07669>
- [48] Pujara, J., Miao, H., Getoor, L., & Cohen, W. (2013). Knowledge Graph identification. In *Lecture notes in computer science* (pp. 542–557). https://doi.org/10.1007/978-3-642-41335-3_34
- [49] HONG, Z. Y., & MA, Z. (2023). Inconsistency Detection in Knowledge Graph with Entity and Path Semantics. *Journal of Information Science and Engineering*, 39(2), 291-303. [https://doi.org/10.6688/JISE.202303_39\(2\).0003](https://doi.org/10.6688/JISE.202303_39(2).0003)
- [50] Choi, S., & Jung, Y. (2025). Knowledge Graph Construction: extraction, learning, and evaluation. *Applied Sciences*, 15(7), 3727. <https://doi.org/10.3390/app15073727>
- [51] Zhao, X., Deng, Y., Yang, M., Wang, L., Zhang, R., Cheng, H., Lam, W., Shen, Y., & Xu, R. (2024). A comprehensive survey on relation extraction: recent advances and new frontiers. *ACM Computing Surveys*, 56(11), 1–39. <https://doi.org/10.1145/3674501>
- [52] Xu, T., & Zhang, F. (2020). A brief review of relation extraction based on Pre-Trained Language Models. *Frontiers in Artificial Intelligence and Applications*. <https://doi.org/10.3233/faia200755>
- [53] Tian, L., Zhou, X., Wu, Y., Zhou, W., Zhang, J., & Zhang, T. (2022). Knowledge graph and knowledge reasoning: A systematic review. *Journal of Electronic Science and Technology*, 20(2), 100159. <https://doi.org/10.1016/j.jnlest.2022.100159>
- [54] Ji, Z., Lee, N., Frieske, R., Yu, T., Su, D., Xu, Y., Ishii, E., Bang, Y., Chen, D., Dai, W., Chan, H. S., Madotto, A., & Fung, P. (2022). Survey of Hallucination in Natural Language Generation. *arXiv (Cornell University)*. <https://doi.org/10.48550/arxiv.2202.03629>

- [55] Xue, B., & Zou, L. (2022). Knowledge Graph Quality Management: a Comprehensive Survey. *IEEE Transactions on Knowledge and Data Engineering*, 1. <https://doi.org/10.1109/tkde.2022.3150080>
- [56] Kim, J., Park, J., & Kim, K. (2025). RSCF: Relation-semantics consistent filter for entity embedding of knowledge graph. In *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics* (pp. 12320–12336). <https://doi.org/10.18653/v1/2025.acl-long.602>
- [57] Li, R., La, K., Lei, J., Huang, L., Ouyang, J., Shu, Y., & Yang, S. (2024). Joint extraction model of entity relations based on decomposition strategy. *Scientific Reports*, 14(1), 1786. <https://doi.org/10.1038/s41598-024-51559-w>
- [58] Zeng, K., Li, C., Hou, L., Li, J., & Feng, L. (2021). A comprehensive survey of entity alignment for knowledge graphs. *AI Open*, 2, 1–13. <https://doi.org/10.1016/j.aiopen.2021.02.002>
- [59] Marchesin, S., Silvello, G., & Alonso, O. (2025). Large language models and data quality for knowledge graphs. *Information Processing & Management*, 62(6), 104281. <https://doi.org/10.1016/j.ipm.2025.104281>
- [60] Simsek, U., Kärle, E., Angele, K., Huaman, E., Opdenplatz, J., Sommer, D., Umbrich, J., & Fensel, D. (2022). A Knowledge Graph Perspective on Knowledge Engineering. *SN Computer Science*, 4(1). <https://doi.org/10.1007/s42979-022-01429-x>
- [61] Dibowski, H., & Gray, F. M. (2020). Applying knowledge Graphs as integrated semantic information model for the computerized engineering of building automation systems. In *Lecture notes in computer science* (pp. 616–631). https://doi.org/10.1007/978-3-030-49461-2_36
- [62] Kashkoush, M., & ElMaraghy, H. (2015). Product family formation by matching Bill-of-Materials trees. *CIRP Journal of Manufacturing Science and Technology*, 12, 1–13. <https://doi.org/10.1016/j.cirpj.2015.09.004>
- [63] Hashemi-Pour, C., Lutkevich, B., & Kakade, S. (2024, December 17). *What is a bill of materials (BOM)?* Search ERP. <https://www.techtarget.com/searcherp/definition/bill-of-materials-BoM>

附錄一

角色設定：你是一個知識圖譜解析器也是材料清單解析器，負責將自然語言字串轉換成結構化的知識圖譜及樹狀材料清單表。

規則：

- 輸入字串為自然語言描述。

1 Entities: 節點陣列。

- 每個節點包含：

- ID: 節點唯一識別碼（可用名稱或自動生成）。

- Name: 節點名稱（名稱相同加序號）。

- Category: 節點抽象分類（陣列）(如 生物分類 界、門、綱、目、科、屬、種)

- Pos: 節點詞別（如「名詞」「代名詞」「專有名詞」「動詞」「數詞」「量詞」）。

- Unit: 節點名稱單位，不可空白。

- Properties: 其他屬性包含 Name:Value（陣列，若沒有則為空陣列）

2 Relations: 關係陣列

- 每個關係包含：

- Source: 關係起點節點 ID（陣列）。

- Target: 關係終點節點 ID（陣列）。

- Relation: 關係名稱（如「包含」「屬於」「擁有」）。

- Pos: 關係名稱詞別（如「名詞」「代名詞」「專有名詞」「動詞」「數詞」「量詞」）。

- Question: 是否為問句

- Seq: 事件順序

- Properties: 其他屬性包含 Name:Value（陣列，若沒有則為空陣列）

- 若字串中有數量描述，需建立數量節點並與對應物件建立「數量」關係。

3 Bom: 材料清單（陣列）

- ":" 左邊是父項

- "," 分隔同層零件

- "x 數字" 表示數量

- "{}" 表示子組件

- ID: 節點 ID(需與 Entities ID 一樣)。

- Qty: 節點數量。
- Unit: 節點單位，不可空白。
- Children 為陣列，若沒有子項則為空陣列
- 每個節點包含 ID,Qty,Unit,Children 四個欄位

4 輸出 JSON 結構包含八大部分：

- 回答語言:中文繁體。
- 所有動詞皆要顯示於關聯。
- Bom 節點不可重複。
- 輸出 JSON 格式，不要解釋。
- 輸出數字使用阿拉伯數字
- 如果是問句無須回答。
- 數詞數量與單位為屬性，無須實體
- 需檢查不可出錯

輸入字串：

〈待輸入的自然語言文本〉

National Formosa University

Extended Abstract

基於物料清單的知識圖譜建構與多來源資料整合方法 Knowledge Graph Construction Based on Bill of Materials and Multi-Source Data Integration Method

Student : Ting-Ying Chang

Advisor: Dar-Li Yang

Department of Information Management
College of Management, National Formosa University

Abstract

This study proposes a knowledge graph (KG) construction method combining Bill of Materials (BOM) structural constraints with multi-source large language model (LLM) output integration, addressing the semantic inconsistency and structural errors prevalent in automated KG construction from heterogeneous sources. By generating structured JSON from multiple LLMs and applying entity alignment, relation semantic classification, and BOM-guided hierarchical validation, the proposed method achieves 100% consistency on short-text data ($n = 100$) and 92% (46/50) on long-text data, compared to 72–86% and 0–4% for single-LLM baselines. The approach provides a reproducible pipeline applicable to manufacturing, supply chain, and biomedical knowledge management tasks.

Keywords: Knowledge Graph, Large Language Model, Bill of Materials, Multi-source Data Integration, Structural Consistency.

1. Introduction

Knowledge graphs (KG) represent entities and relationships as structured triples and have been widely applied in search engines[1], recommendation systems[2], and question-answering systems[3]. Traditional KG construction relies on manual ontology design and annotation—costly and difficult to scale—while multi-source integration introduces additional risks of entity naming conflicts and structural mismatches. Recent advances in LLMs offer a promising path toward automated KG construction through few-shot or zero-shot prompting [4], yet LLM outputs suffer from entity boundary ambiguity, inconsistent naming, erroneous relation semantics, and hierarchical disorder, especially when integrating outputs across multiple models [5].

To address these challenges, this study introduces the Bill of Materials (BOM) structure—with its explicit parent-child compositional hierarchy—as a normalization backbone for multi-source LLM output integration. The method reduces entity redundancy, relationship errors, and hierarchical conflicts while improving semantic correctness and structural completeness of the resulting KG.

2. Methodology

The pipeline comprises four stages. (1) Structured data generation: prompt engineering directs two LLMs to convert natural language into unified JSON containing Entities (ID, name, category, properties), Relations (source, target, relation name, sequence), and BOM (parent-child tree with quantity and unit). An iterative validation loop (up to five cycles) checks structural rules—BOM IDs must exist in entities, relation endpoints must reference valid entities, and unit fields must be non-empty—feeding error messages back to the LLM for regeneration. (2) JSON reorganization: relations are classified into six semantic types (None, General, Base, Detail, Function, Number) using a cosine similarity threshold of 0.7. Detail-type relations already represented in BOM are removed to prevent redundancy; noun-type relations are converted to entity attributes. (3) Multi-source alignment: a reference JSON is selected by prioritizing BOM node count. Other JSONs are aligned via entity name similarity (threshold 0.8) and mean-pooled attribute semantic vectors (threshold 0.7); missing entities and relations are supplemented selectively by type to balance completeness and conciseness. (4) KG construction and evaluation: the final graph is assessed

across four dimensions—entity consistency, relation semantic consistency, structural correctness, and structural completeness—against a human-verified reference.

3. Results

Three methods were compared: (A) single LLM without BOM, (B) single LLM with BOM, and (C) the proposed multi-source LLM with BOM. On 100 short-text samples, A achieved 72–77 consistent results, B improved to 81–86, and C reached 100. On 50 long-text samples, A and B yielded only 0–2 consistent results, while C achieved 46, demonstrating strong robustness under high semantic complexity.

Case analysis confirmed the mechanism: in a food ingredient description, the single LLM extracted only 2 of 5 entities and missed all functional relations; the proposed method captured all 5 entities and the "prepare" relation through multi-model complementarity. In an equipment composition case, the single LLM identified only static structural components; the proposed method additionally extracted 3 process entities (fat globule, micro-particle, cream separation) and 3 functional causal relations, with BOM constraints separating compositional from operational semantics.

4. Discussion

BOM structural constraints primarily improve hierarchical correctness by preventing level-mixing errors, with the strongest effect on short texts where compositional structure is explicit. Multi-source integration improves semantic completeness by leveraging complementary model coverage, with the most pronounced benefit on long texts where single models fail almost entirely. The semantic similarity thresholds (0.7–0.8) require empirical calibration; future work should investigate threshold sensitivity and adaptive threshold strategies. The current evaluation relies on a human-verified multi-source output as reference rather than an external gold standard, which limits absolute accuracy measurement. The BOM constraint is less effective for texts lacking clear hierarchical structure, such as flat parallel or temporal event descriptions.

5. Conclusions

This study presents a KG construction pipeline that combines multi-source LLM integration with BOM structural constraints to overcome the semantic inconsistency and structural incompleteness of single-model approaches. The method achieves substantial performance gains

on both short and long texts and offers broad applicability in smart manufacturing, supply chain management, automated enterprise knowledge bases, biomedical knowledge integration, and Graph-RAG systems. Future directions include expansion to real-domain expert-annotated datasets, systematic evaluation of larger LLM ensembles, automated KG quality evaluation mechanisms, and incremental update support for dynamic KG maintenance.

Reference

- [1] Liu, J., Ren, J., Zheng, W., Chi, L., Lee, I., & Xia, F. (2022). Web of Scholars: A Scholar Knowledge Graph. *arXiv (Cornell University)*. <https://doi.org/10.48550/arxiv.2202.11311>
- [2] Wang, X., He, X., Cao, Y., Liu, M., & Chua, T. (2019). KGAT: Knowledge Graph Attention Network for Recommendation. *arXiv (Cornell University)*. <https://doi.org/10.48550/arxiv.1905.07854>
- [3] Bao, J., Duan, N., Yan, Z., Zhou, M., & Zhao, T. (2016, December 1). *Constraint-Based Question Answering with Knowledge Graph*. ACL Anthology. <https://aclanthology.org/C16-1236/>
- [4] Gao, T., Fisch, A., & Chen, D. (2020). Making pre-trained language models better few-shot learners. *arXiv (Cornell University)*. <https://doi.org/10.48550/arxiv.2012.15723>
- [5] Xu, D., Chen, W., Peng, W., Zhang, C., Xu, T., Zhao, X., Wu, X., Zheng, Y., Wang, Y., & Chen, E. (2024). Large language models for generative information extraction: a survey. *Frontiers of Computer Science*, 18(6). <https://doi.org/10.1007/s11704-024-40555-y>